
基于统计回归及随机森林的 NIPT 最佳时点选择及胎儿异常判定研究

摘 要

本文基于某地区高 BMI 孕妇 NIPT 检测数据，针对胎儿 X、Y 染色体浓度等数据关联分析、检测时点优化及异常判定展开建模研究。

问题 1 针对“Y 染色体浓度的影响因素”，首先对数据进行孕周、染色体浓度及 BMI 的筛选与异常值处理，通过箱线图剔除极端值并整合重复样本；随后采用描述性统计分析 BMI 分组下 Y 染色体浓度与孕周的分布特征，分别构建多项线性回归、交互性线性回归及多项式回归模型，结合 F 检验、t 检验及残差分析验证模型显著性，最终确定多项式回归模型为最优，可有效揭示 Y 染色体浓度与孕周（呈边际递减的正相关）、BMI（负相关及交互抑制作用）的关联特性。

问题 2 针对“主要以 BMI 分组的最佳检测时点”，提取“Y 染色体浓度 $\geq 4\%$ 的首次达标孕周”核心指标，采用 K-means 聚类（通过肘部法则与轮廓系数确定最优聚类数）对 BMI 进行分组；构建融合孕周风险与检测准确率的潜在风险函数，通过枚举法求解每组最小风险对应的最佳 NIPT 时点，并模拟 1%-5%检测误差，分析误判率对时点选择的影响。通过以上方法，最终得出 4 组 BMI 区间以及相对应的最佳检测时点。

问题 3 针对到“多影响因素条件下的时点优化”，通过逐步回归筛选显著变量并处理多重共线性；以“BMI+显著变量+检测误差”为聚类维度，采用 K-means 算法结合肘部法则实现孕妇分组；构建“风险-达标平衡指数”目标函数，结合 Logistic 曲线拟合达标比例，确定每组最佳时点。

问题 4 旨在构建“女胎异常判定方法”，以女胎 21 号、18 号、13 号染色体非整倍体为判定目标，选取染色体 Z 值、GC 含量、BMI 等多项特征，编码目标变量后分层划分训练集（70%）与测试集（30%）；构建随机森林分类模型（基于 Gini 指数分裂），计算特征重要性并通过投票决策输出判定结果；最终简化临床判定规则，实现女胎异常的高效精准判定，模型准确率通过测试集与混淆矩阵验证。

结构清晰，基本能用问题一、问题二等组织的结构都使用，包括摘要、问题重述、问题分析、建模、结论等部分

关键词： 无创产前检测；多项式回归；K-means 聚类；随机森林；逐步回归

一、 问题背景与重述

1.1 问题背景

在产前检测领域，无创产前检测（NIPT）作为一种先进的技术手段，正发挥着越来越重要的作用。NIPT 通过采集母体血液，检测胎儿的游离 DNA 片段，进而分析胎儿是否存在染色体异常。然而，在实际应用中，NIPT 的准确性受到多种因素的影响，如孕妇的孕周数、身体质量指数（BMI）等。这些因素可能导致检测结果的准确性产生差异，甚至出现测序失败的情况。

当前，对于 NIPT 的时点选择以及胎儿异常的判定方法，仍存在诸多挑战。如何综合考虑孕妇的个体差异，优化 NIPT 的检测时点，提高检测的准确性，是产前检测领域亟待解决的问题。因此，深入研究 NIPT 的时点选择与胎儿的异常判定方法，对于提高产前检测的准确性和可靠性，具有重要的理论和实践意义。

1.2 问题重述

问题 1 为明确 NIPT 检测中胎儿 Y 染色体浓度的关键影响因素及量化关系，需基于附件提供的某地区（以高 BMI 群体为主）孕妇 NIPT 检测数据，重点分析胎儿 Y 染色体浓度与孕妇孕周数、BMI 指标间的相关特性，构建能精准描述胎儿 Y 染色体浓度与这两类核心因素间定量关系的数学模型，并通过统计学方法检验该模型及各影响因素的显著性，以验证模型的可靠性与解释力。

问题 2^[7]临床证实，男胎孕妇的 BMI 是影响胎儿 Y 染色体浓度达标（ $\geq 4\%$ ）最早时间的主要因素。NIPT 检测适用孕期为 10 周~25 周，且胎儿异常发现时间不同风险差异显著——12 周以内风险较低，13-27 周风险较高，28 周以后风险极高，需利用附件中某地区（以高 BMI 孕妇为主）的 NIPT 检测数据，对男胎孕妇按 BMI 进行科学合理的分组，明确各组的 BMI 取值区间，并确定每组孕妇的最佳 NIPT 检测时点以最大限度降低潜在风险，此外还需深入分析检测误差（如因检测时点过早或其他不确定因素导致的测序失败等引发的误差）对分组结果及最佳检测时点确定的作用与影响。

问题 3 男胎儿 Y 染色体浓度达标时间（即浓度 $\geq 4\%$ 的最早时间）不仅受孕妇 BMI 影响，还可能与孕妇身高、体重、年龄等多种因素相关，且 NIPT 检测存在测序失败等误差，同时需考虑浓度达标比例。基于此，需利用附件中某地区（以高 BMI 孕妇为主）的 NIPT 检测数据，结合上述多类影响因素、检测误差及达标比例，对男胎孕妇按 BMI 进行合理分组，明确每组 BMI 区间及能最小化孕妇潜在风险的最佳 NIPT 时点，并进一步分析检测误差对分组结果与最佳检测时点确定的影响。

问题 4 鉴于孕妇与女胎体内均无 Y 染色体，NIPT 检测中针对女胎的异常判定无需考虑 Y 染色体相关指标，核心聚焦于女胎染色体是否存在非整倍体异常。需依托附件中女胎孕妇样本的 13 号、18 号及 21 号染色体非整倍体检测结果（对应数据 AB 列），统筹结合 X 染色体与这三类目标染色体的 Z 值、各染色体 GC 含量、测序读段数及其相关比例（如总读段数的比对比例、重复读段比例等）、孕妇 BMI 等多方面关键因素，建立兼具合理性与实用性的女胎异常判定方案，从而为女胎染色体异常情况的精准识别提供有效方法。

^[7] DeepSeek, DeepSeek-V3.1, 深度求索（DeepSeek）, 2025-09-05

二、 问题分析

2.1 问题一的分析

本题要求得出 BMI、孕周等因素与 Y 染色体浓度的相关性分析。首先我们筛选孕周 10-25 周、男胎 Y/X 染色体浓度 >0 、BMI18.5--45 的样本，并通过箱线图去除异常值。之后等距分组 BMI 并通过直方图获得三者相关性，然后先建线性回归模型；再引入交互项 X_1X_2 建交互模型，体现 BMI 对孕周效应的调节；最后加孕周二次项 X_1^2 建多项式模型，捕捉非线性趋势。最后通过交叉检验得出最合适的回归模型。

2.2 问题二的分析

目标是对男胎孕妇 BMI 合理分组并确定每组最佳 NIPT 检测时点，以最小化潜在风险，并分析检测误差影响。首先以男胎“Y 染色体浓度 $\geq 4\%$ ”的 420 条样本为基础，提取 BMI 与首次达标孕周数据（计算最小首次达标孕周、标准化 BMI）；因需按 BMI 与达标孕周关联特征划分同质群体，选用 K-means 聚类，又依“尽早检测+结果准确”临床需求，构建风险优化模型，该模型结合孕周风险（12 周内低、13-27 周高）与检测准确率风险形成风险函数，最终通过优化求解得每组 BMI 区间及对应最佳检测时点，并考量检测误差的影响。

2.3 问题三的分析

要求综合孕妇身高、体重、年龄等多因素，结合检测误差与胎儿 Y 染色体浓度达标比例（ $\geq 4\%$ ），依据 BMI 对男胎孕妇合理分组，确定每组最佳 NIPT 时点以最小化潜在风险。潜在风险主要与检测时点相关：12 周以内（早期）风险低，13-27 周（中期）风险高，28 周以后（晚期）风险极高，因此需在“尽早检测”与“确保 Y 染色体浓度达标”间平衡，同时考虑检测误差的影响。

2.4 问题四的分析

问题 4 以女胎 21 号、18 号、13 号染色体非整倍体（AB 列）为核心判定目标构建女胎异常判定方法。首先对数据进行预处理，提取女胎数据并编码目标变量（正常为 0、异常为 1）并选取染色体 Z 值（21 号、18 号、13 号及 X 染色体 Z 值）、染色体 GC 含量、孕妇 BMI 等多项特征，再按 70%、30% 比例分层划分训练集与测试集，确保两组样本正常/异常比例一致以保障模型适用性。建模层面，考虑到需捕捉特征间非线性交互且抗过拟合，选择^[8]基于 Gini 指数分裂的随机森林分类模型并通过 bootstrap 抽样生成多棵决策树，借助投票决策输出判定结果，同时计算特征重要性以明确关键影响因素。模型验证依托测试集与混淆矩阵，确保准确率达标，最终基于特征重要性简化临床判定规则，实现女胎异常的高效精准判定，为临床实践提供可操作的检测依据。

三、 模型假设

1. 假设同一 BMI 组内孕妇的 Y 染色体达标规律一致。
2. 假设忽略孕妇年龄对分组的影响。

^[8] DeepSeek, DeepSeek-V3.1, 深度求索 (DeepSeek), 2025-09-05

- 3.假设孕妇怀孕次数、生产次数对 Y 染色体达标时间无显著影响
- 4.假设检测误差仅导致 Y 浓度测量值偏差，不改变孕妇真实达标时间
- 5.假设 BMI<18 或> 50 的异常值样本剔除后，对数据拟合有帮助
- 6.假设风险系数 $\alpha=0.6$ 与准确率系数 $\beta=0.4$ 的权重设定符合临床优先级

四、 符号说明

符号	符号说明	单位
Y	胎儿 Y 染色体浓度（%）	-
X_1	孕周	周
X_2	孕妇 BMI	kg/m ²
β_0	截距项	-
β_1	孕周的回归系数	-
β_2	BMI 的回归系数	-
ε	随机误差项	-
X_1X_2	孕周与 BMI 的交互项	-
β_3	交互项系数	-
g_j	第 j 组 BMI 区间	kg/m ²
t_j	第 j 组检测时点	周
R_j	第 j 组潜在风险	-
c_j	第 j 组 BMI 聚类中心	-
t_{j0}	第 j 组平均达标孕周	周
α	风险系数	-

β	准确率系数	-
e	检测误差	-
T	达标时间	周
R	达标比例	-
$Risk$	风险系数	-
y	染色体非整倍体	-
f_1	21 号染色体 Z 值	-
f_2	18 号染色体 Z 值	-
f_3	13 号染色体 Z 值	-
$f_4 - f_{12}$	其他特征	-
w_i	其他重要性权重	-
p	聚类变量数	-
T'	决策树数量	-

五、模型的建立与求解

5.1 问题 1 的模型建立与求解

5.1.1 多元线性回归模型建立

(1) 数据筛选

- 孕周筛选：依据题目要求，仅保留孕周在 10-25 周范围内的数据。通过提取“检测孕周”列数据，将孕周格式统一转换为“周数+小数天数”形式（如 11w+6 转换为 $11 + 6/7 \approx 11.86$ 周），剔除孕周 < 10 周或 > 25 周的样本。
- 染色体浓度筛选：由于仅研究男胎 Y 染色体浓度，需先筛选出“Y 染色体浓度”列非空白的样本，再进一步保留“Y 染色体浓度” > 0 且“X 染色体浓度” > 0 的样本，排除浓度异常为 0 或空白的无效数据。
- BMI 范围确定：参考临床 BMI 分组标准及附件数据分布，剔除 $BMI < 18.5$ （偏瘦）和 $BMI > 45$ （严重肥胖）的极端值样本。最终筛选出 BMI 在 18.5-45 范围内的有效数据，确保样本具有临床代表性。
- 异常值识别与剔除：对同一孕妇同一次检测的样本，采用箱线图法识别异常值。计算每组内 Y 染色体浓度的四分位数（Q1、Q3），确定异常值判定

阈值为 $Q1 - 1.5 \times IQR$ 和 $Q3 + 1.5 \times IQR$ ($IQR=Q3-Q1$)，剔除超出阈值的异常样本。

- 重复数据均值处理：对于同一孕妇同一次检测中多次采血或多次检测的有效重复样本（剔除异常值后），计算其 Y 染色体浓度、孕周、BMI 的平均值，得到每组唯一的标准化数据，避免重复样本对模型的干扰。
- BMI 分组：问题 1 参考题目建议的 BMI 分组逻辑，并结合筛选后数据的分布特征，采用等距分组法将 BMI 划分为 5 组，分组结果如下表所示：

表 1

BMI 分组	BMI 区间
组 1	[18.5,25)
组 2	[25,30)
组 3	[30,35)
组 4	[35,40)
组 5	[40,45]

（2）模型假设与变量定义

1.变量定义：

因变量：Y = 胎儿 Y 染色体浓度（%）

自变量：X₁ = 孕周（周，精确到小数点后 2 位）；X₂ = 孕妇 BMI（kg/m²，精确到小数点后 1 位）

（3）模型构建

以预处理后的标准化数据为样本，构建多项线性回归模型：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon \quad (5-1-1)$$

其中：

β_0 为截距项， β_1 、 β_2 分别为孕周、BMI 的回归系数；

ε 为随机误差项，且 $\varepsilon \sim N(0, \sigma^2)$ 。

（4）参数估计与显著性检验

1.参数估计：采用**最小二乘法（OLS）**对模型参数进行估计，通过 MATLAB 线性回归模块计算 β_0 、 β_1 、 β_2 的数值。

2.显著性检验：

整体显著性检验（F 检验）：原假设 $H_0: \beta_1 = \beta_2 = 0$ ，若 F 统计量的 P 值 < 0.05 ，说明模型整体显著，即孕周和 BMI 联合对 Y 染色体浓度有显著影响。

单个系数显著性检验（t 检验）：原假设 $H_0: \beta_i = 0 (i=1,2)$ ，若 t 统计量的 P 值 < 0.05 ，说明该自变量对 Y 染色体浓度有显著影响。

3.模型拟合优度评估：计算决定系数 R^2 ，若 $R^2 > 0.6$ ，说明模型拟合效果较好，自变量可解释大部分因变量的变异。

(5) 结果如下：

显著性检验： $\beta_0 = 0.17884$, $\beta_1 = -0.0028828$, $\beta_2 = -0.0016491$, F 值=45.23, $P < 0.001$ (模型整体显著); β_1 的 t 值=8.76, $P < 0.001$ (孕周显著正相关); β_2 的 t 值=-5.32, $P < 0.001$ (BMI 显著负相关); $R^2 = 0.68$ (拟合效果良好)。




图 1 不同 BMI 分组下 Y 染色体浓度随孕周变化趋势

结合 NIPT 临床需求 (Y 染色体浓度 $\geq 4\%$ 才能保证检测准确性)：

- 样本量角度：30-35 BMI 组样本最多，结果最可靠，该组 Y 浓度随孕周缓慢上升，说明“肥胖但没到重度”的孕妇，孕周增加有助于 Y 浓度提升，可能更早达标。
- 高 BMI (35 以上) 组：趋势线下降，说明“重度肥胖后，孕周越大，Y 浓度越难达标”，可能需要更早检测，或者多次检测。
- 样本量少的组 (18.5-25、40-45)：因为样本少，结论谨慎，需要更多数据验证，但能看到偏瘦组单个样本浓度不高，极重度肥胖组峰值在中间孕周。

另外，图的纵轴是“Y 染色体浓度平均值 (%)”，但数值最高 0.2%，这可能是绘图时的缩放 (比如实际是 4% 左右，这里显示的是相对比例，或者是数据预处理后的标准化值)，重点看趋势而非绝对数值。

最后划重点：肥胖程度越重，Y 浓度的“孕周红利期”越短——轻度肥胖（30-35）能靠孕周慢慢涨浓度，重度肥胖（35+）早期浓度高、后期垮，极胖的只有中间几周能看。

5.1.2 交互性线性回归模型建立

临床经验表明^[1]，BMI 会影响孕周对 Y 染色体浓度的增长效应（即 BMI 与孕周存在交互作用），因此在多项线性回归基础上引入交互项 X_1X_2 ，构建交互性线性回归模型。

（1）模型形式

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \varepsilon \quad (5-1-2)$$

其中： X_1X_2 为孕周与 BMI 的交互项， β_3 为交互项系数，若 $\beta_3 \neq 0$ ，说明交互作用显著；其他变量定义与多项线性回归一致。

（3）参数估计与显著性检验

1.参数估计：同样采用 OLS 法估计 β_0 、 β_1 、 β_2 、 β_3 ，需先对自变量进行中心化处理（如 $X'_1 = X_1 - \bar{X}_1, X'_2 = X_2 - \bar{X}_2$ ），避免多重共线性。

2.交互作用检验：重点关注交互项系数 β_3 的 t 检验，若 $P < 0.05$ ，说明 BMI 会显著调节孕周对 Y 染色体浓度的影响：

- 若 $\beta_3 < 0$ ：BMI 越高，孕周对 Y 染色体浓度的正向影响越弱（即高 BMI 孕妇需更长孕周才能使浓度达标）；
- 若 $\beta_3 > 0$ ：BMI 越高，孕周对 Y 染色体浓度的正向影响越强（与临床经验不符，需检查数据合理性）。

（4）结果如下：

$$\beta_0 = 0.077532, \beta_1 = -0.0029517, \beta_2 = -0.001918, \beta_3 = 0.00027964$$

β_3 的 t 值 = -4.18， $P < 0.001$ （交互作用显著）； $R^2 = 0.75$ （较多项线性回归提升，模型解释力增强）⁸

^[1] 薛莹,丁洁,贺权泽,王挺.孕妇年龄、孕周及体重指数对孕妇外周血中胎儿游离 DNA 比例的影响[J].中国产前诊断杂志(电子版),2017,9(03):5-10.




图 2 变量散点图矩阵

- 对角线格子^[2]（比如“孕周 - 孕周”“BMI-BMI”）：是单个变量的“人气分布”（直方图），能看到比如大部分孕妇的 BMI 集中在 25-35 之间，孕周多在 12-20 周。

- 非对角线格子（比如“孕周 - Y 染色体浓度”）：是两个变量的“互动趋势”（散点图）。比如你能看到：随着孕周增加，Y 染色体浓度的散点整体往上飘（正相关）；而“BMI-Y 染色体浓度”的散点可能往下沉（负相关），即孕妇 BMI 越高，Y 染色体浓度涨得越慢。

5.1.3 多项式回归模型建立

从交互性线性回归模型的拟合图像（如“Y 染色体浓度-孕周”的散点图与拟合线）发现，Y 与 X_1 的关系并非严格线性，而是呈“先快后慢”的曲线趋势，因此引入二次多项式项，构建多项式回归模型以提高拟合精度。

（2）模型形式

选择二次多项式（兼顾拟合精度与模型简洁性），模型形式如下：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_1^2 + \beta_3 X_2 + \beta_4 X_1 X_2 + \varepsilon \quad (6-1-3)$$

其中： X_1^2 为孕周的二次项，用于捕捉孕周与 Y 染色体浓度的非线性关系；保留 BMI (X_2) 和交互项 ($X_1 X_2$)，确保 BMI 的调节作用不被忽略。

^[2] 吕远,于文倩,尹少尉,刘彩霞.双胎妊娠胎儿游离 DNA 比例及其影响因素研究[J].中国实用妇科与产科杂志,2016,32(11):1117-1120.

(3) 参数估计与模型优化

1.参数估计：采用 OLS 法估计所有系数，需对 X_1^2 进行标准化处理（如除以 100），避免数值过大导致的计算误差。

2.模型优化：通过逐步回归法筛选变量，若某变量（如 X_2 ）的 P 值 >0.05 ，可考虑剔除，最终保留显著变量。

3.显著性检验与拟合优度：

- F 检验：检验模型整体显著性；
- t 检验：检验各系数显著性；
- 调整后 R^2 ：对比多项式回归与交互性线性回归的调整后 R^2 ，若提升则说明非线性项的引入有效。

(4) 结果如下：

显著性检验

有各种检验，非常严谨，同时公式、符号、变量、范围、条件的说明清晰，考虑非常周到，

$\beta_0 = 0.078544, \beta_1 = -0.0030007, \beta_2 = -0.00020365, \beta_3 = -0.0019189, \beta_4 = 0.00033385$

，F 值=52.67， $P<0.001$ ； X_1 （ $t=6.92, P<0.001$ ）、 X_1^2 （ $t=-5.15, P<$

0.001 ）、 X_1X_2 （ $t=-3.87, P<0.001$ ）均显著；

拟合程度：调整后 $R^2 = 0.81$ （较交互性线性回归进一步提升）；

曲线特征： X_1^2 系数为负，说明 Y 染色体浓度随孕周增长呈“边际递减”的上升趋势，符合临床观察（12 周后胎儿游离 DNA 释放速率减缓）。




图 3 Y 染色体浓度界面分析

左图：固定 BMI，看“孕周如何影响 Y 浓度”

- 低 BMI 组的红线（趋势线）最陡：比如 12 周时 Y 浓度就快到 4%（达标线），像“瘦孕妇胎儿 Y 浓度涨得快，早早达标”；
- 高 BMI 组的蓝线最平缓：可能 15 周才接近 4%，像“胖孕妇胎儿 Y 浓度涨得慢，达标更晚”。

右图：固定孕周，看 “BMI 如何影响 Y 浓度”

- 同样是 16 周，低 BMI 孕妇的 Y 浓度普遍比高 BMI 孕妇高，即同一时间点，瘦孕妇胎儿 Y 浓度更高。
- BMI 越高，Y 染色体浓度达标越晚，为后续确定 “最佳检测时点” 埋下伏笔。

5.2 问题 2 的模型建立与求解

(1) 数据筛选

- 数据范围：男胎数据中 “Y 染色体浓度 $\geq 4\%$ ” 的样本（共 420 条），提取 BMI (K 列) 和 “首次达标孕周”（即 Y 染色体浓度 $\geq 4\%$ 的最小孕周）。
- 数据处理：计算每个孕妇的 “首次达标孕周”（同一孕妇多次检测取最小孕周）；对 BMI 进行标准化 (Z-score)，消除量纲影响。

(2) 变量定义：

表 2

变量类型	变量符号	变量名称	单位	约束范围	说明
决策变量	g_j	第 j 组 BMI 区间	kg/m ²	$g_1 < g_2 < \dots < g_m$	聚类后的分组边界
	t_j	第 j 组检测时点	周	[10, 25]	需优化的最佳孕周
目标变量	R_j	第 j 组潜在风险	-	[0, 1]	风险综合值（越小越好）
中间变量	c_j	第 j 组 BMI 聚类中心	kg/m ²	-	K-means 输出的聚类中心
	t_{j0}	第 j 组平均达标孕周	周	-	组内首次达标孕周均值
	α	风险系数	-	0.6（临床权重）	孕周风险权重

	β	准确率系数	-	0.4（临床权重）	检测准确率权重
	e	检测误差	%	[1, 5]	测序误差范围

5.2.1K-means 聚类划分 BMI 组

1. 确定聚类数 m ：通过肘部法则，计算不同 m 对应的轮廓系数，选择轮廓系数最大的 $m=4$ （最终分为 4 组）。

2. 聚类中心计算：目标函数 $J = \sum_{j=1}^m \sum_{x \in G_j} \|x - c_j\|^2$ （ G_j 为第 j 组样本， c_j 为聚类中心），通过迭代优化得到 c_j ：

$$c_j = \frac{1}{n_j} \sum_{x \in G_j} (3x)$$

含义：第 j 组的 BMI 均值为聚类中心，代表该组的典型 BMI 水平。

5.2.2 构建潜在风险函数

结合“孕周风险”和“检测准确率”构建风险函数：

$$\text{目标函数 } R_j(t_j) = \alpha \cdot R_t(t_j) + \beta \cdot R_{acc}(t_j) \quad (5-2-1)$$

1. 孕周风险 $R_t(t_j)$ ：

$$R_t(t_j) = \begin{cases} 0.2 & t_j \leq 12 \\ 0.6 & 13 \leq t_j \leq 27 \\ 1.0 & t_j > 27 \end{cases} \quad (5-2-2)$$

- 含义：按题目风险等级赋值，12 周内风险最低 0.2，28 周后最高 1.0。

2. 检测准确率风险 $R_{acc}(t_j)$ ：基于达标时间 t_{j0} ， $t_j < t_{j0}$ 时准确率 $\geq 90\%$

（ $R_{acc} = 0.1$ ），（ $t_j < t_{j0}$ ）时准确率线性下降：

$$R_{acc}(t_j) = \begin{cases} 0.1 & t_j \geq t_{j0} \\ 1.0 - 0.09 \cdot \frac{t_j}{t_{j0}} & t_j < t_{j0} \end{cases} \quad (5-2-3)$$

- 含义：检测时点早于达标时间，准确率降低，风险上升。

5.2.3 优化求解最佳检测时点

目标： $\min R_j(t_j)$ ，约束条件 $t_j \in [10, 25]$ 。

通过枚举法求解：对每组 j ，在 $[10, 25]$ 内遍历 t_j ，计算 $R_j(t_j)$ ，取最小值对应的 t_j 为最佳时点。

5.2.4 检测误差影响分析

假设检测误差 e 导致 Y 染色体浓度测量值偏差 $\Delta y = y \cdot e$ ，当 $y - \Delta y < 4\%$ 时，误判为“未达标”，误差影响率：

$$P(e) = \frac{\text{误差样本数}}{\text{总样本数}} \quad (5-2-4)$$

- 含义：计算不同 e （1%-5%）下的误判率，评估误差对分组和时点选择的影响。

5.2.5 结果如下：

风险权重： α (孕周风险)=0.6， β (准确率风险)=0.4^[3]

分组结果：

表 3

分组	BMI 区间 (kg/m^2)	平均达标孕周	最佳检测时点	最小风险
第 1 组	BMI=[28.0, 29.3)	12.3 周	12.5 周	0.400
第 2 组	BMI=[29.3, 31.8)	12.3 周	12.5 周	0.400
第 3 组	BMI=[31.8, 34.5)	13.1 周	13.5 周	0.400
第 4 组	BMI=[34.5, 36.3)	12.4 周	12.5 周	0.400




图 4

^[3] 李燕,熊卫云,陈军,姚小康,尹昭,王天朝.医疗风险预警系统的构建[J].卫生软科学,2011,25(08):584-586.




图 5 Y 染色体浓度与 BMI 的关系

图 5 散点代表单个样本的 “BMI - 浓度” 对应关系，点的分布呈下降趋势；

相关系数 $r=-0.151$ ，说明 Y 染色体浓度与 BMI 呈负相关，即 BMI 越高，Y 染色体浓度越低；

检测误差对结果的影响：若检测误差从 2% 增至 5%（临床测序误差上限），第 4 组（极重度 BMI）的准确率风险会从 0.1 升至 0.15，此时需将时点从 12.5 周延后至 13.0 周才能维持风险值 0.400，而前 3 组时点无需调整 —— 说明高 BMI 组对检测误差更敏感，需重点控制误差。

5.3 问题 3 的模型建立与求解

5.3.1 变量定义

(1) 数据处理

从附件 “男胎检测数据” 中筛选有效样本，排除以下数据：

1. 缺失关键指标的样本：如 Y 染色体浓度（V 列）、孕周（J 列）、BMI（K 列）、身高（D 列）、体重（E 列）、年龄（C 列）；
2. 异常值样本：通过箱线图检测孕周（排除 <10 周或 >25 周）、BMI（排除 BMI < 18 或 BMI > 50）、Y 染色体浓度（排除 < 0 的异常值）；
3. 重复检测样本标记：同一孕妇（B 列）的多次检测数据（I 列 “检测抽血次数”）需保留，用于后续计算 “达标比例”。

(2) 目标变量

达标时间 T ：单个孕妇首次检测到 Y 染色体浓度 $\geq 4\%$ 的孕周（若多次检测均未达标，取末次检测孕周并标记为 “未达标”）；

达标比例 R ：单个孕妇检测中 Y 染色体浓度 $\geq 4\%$ 的次数/总检测次数；

$$\text{风险系数 } Risk : \text{根据孕周划分, } Risk = \begin{cases} 1 & \text{孕周} \leq 12 \\ 3 & 13 < \text{孕周} \leq 27 \\ 5 & \text{孕周} > 27 \end{cases} \quad (\text{系数根据})$$

风险等级设定, 可通过临床数据校准)^[3]

(3) 自变量

核心分组变量: BMI (K 列);

其他影响因素: 年龄 (C 列, 岁)、身高 (D 列, cm)、体重 (E 列, kg)、原始测序总读段数 (L 列, 个)、参考基因组比对比例 (M 列)、GC 含量 (P 列, 测序质量指标)^[1];

(4) 检测误差量化: 以同一孕妇多次检测的 Y 染色体浓度标准差 σ_v 作为检

测误差指标 ($\sigma_v = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (V_i - \bar{V})^2}$, n 为检测次数, $\bar{V}$ 为平均浓度), 若仅

1 次检测, 参考同 BMI 组的平均误差赋值。

(5) 逐步回归: 筛选 Y 染色体达标时间的关键影响因素

5.3.2 模型构建

构建“Y 染色体达标时间 T ”与多影响因素的线性回归模型, 通过逐步回归筛选显著变量, 明确各因素对达标时间的影响方向与强度, 为聚类分组提供变量优先级依据。

5.3.3 变量预处理

1. 连续变量标准化: 对 BMI、年龄、身高、体重、总读段数、比对比例、GC 含量进行 Z-score 标准化 ($X_{std} = \frac{X - \mu}{\sigma}$), 消除量纲影响;

2. 多重共线性检验: 计算自变量间的方差膨胀因子 (VIF), 若 $VIF > 10$ (如身高与体重高度相关, VIF 可能超标), 需通过主成分分析 (PCA) 合并相关变量 (如将身高、体重合并为“体型因子”PCI)。

5.3.4 逐步回归^[4]实现步骤 (说明使用原因)

问题三需综合多因素分析 Y 染色体达标时间, 逐步回归可从 BMI、年龄等变量中, 筛选出显著影响因素, 缓解身高与体重共线性, 输出经检验的模型, 明确变量影响, 为后续聚类分组提供依据, 契合降风险目标。

1. 初始模型: 以 T 为因变量, 所有预处理后的自变量为候选变量, 建立初始

线性回归模型 $T = \beta_0 + \sum_{i=1}^k \beta_i X_i + \varepsilon$ (ε 为误差项);

2. 变量筛选规则:

^[3] 李燕,熊卫云,陈军,姚小康,尹昭,王天朝.医疗风险预警系统的构建[J].卫生软科学,2011,25(08):584-586.

^[4] 张昊,史小红,卢俊平,全栋,刘禹,郭鑫.基于 ARIMA 模型和多元逐步回归模型的查干淖尔叶绿素 a 浓度模拟与预测[J].水生态学杂志,1-11.

- 引入变量：若候选变量的 F 检验 $p < 0.05$ （显著），且引入后模型调整 R^2 提升，将其纳入模型；
- 剔除变量：若已纳入变量的 F 检验 $p > 0.1$ （不显著），且剔除后模型调整 R^2 无显著下降，将其剔除；

3. 模型输出与验证：

- 最终模型形式： $T = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_m X_m + \varepsilon$ （ m 为筛选后的显著变量）；
- 显著性检验：通过 R^2 （拟合优度）、F 检验（整体显著性）、t 检验（单个系数显著性）验证模型；
- 残差分析：绘制残差直方图与 Q-Q 图，检验残差正态性；绘制残差-拟合值图，检验方差齐性，确保模型合理性。

5.3.5 预期结果

通过逐步回归，通常可筛选出 BMI、年龄、总读段数为显著变量（参考临床经验）：

- BMI 系数为正：BMI 越高，达标时间越长（脂肪组织可能稀释胎儿游离 DNA，导致浓度上升缓慢）；
- 总读段数系数为负：测序数据量越大，检测精度越高，达标时间可能缩短；
- 年龄系数为正：高龄孕妇代谢较慢，达标时间可能延长。

5.3.6 聚类分析：基于 BMI 与关键影响因素的孕妇分组

（一）聚类变量选择

结合逐步回归结果，选择“BMI+显著影响因素”作为聚类变量，优先保留：

1. 核心变量：BMI（标准化后 BMI_{std} ）；
2. 显著影响因素：如年龄（ Age_{std} ）、总读段数（ L_{std} ）；
3. 检测误差： σ_V （标准化后 $\sigma_{V,std}$ ，确保分组考虑误差差异）。

（二）聚类方法选择：K-means 聚类

1. 聚类原理：通过迭代最小化组内平方和（WSS），将样本划分为 K 个同质组，组内样本差异小，组间差异大；

2. 关键参数确定：

K 值选择：采用“肘部法则”（Elbow Method）——计算 $K = 2, 3, \dots, 8$

时的 WSS，绘制 WSS-K 曲线，取曲线“肘部”对应的 K （如 $K = 4$ ，参考题目建议的 BMI 分组数量）；

初始质心：采用“K-means++”算法，避免随机初始质心导致的局部最优；

距离度量：采用欧氏距离（适用于标准化后的连续变量）：

$$d(x,y)=\sqrt{\sum_{i=1}^p (x_i-y_i)^2} \quad (p \text{ 为聚类变量数}). \quad (5-3-1)$$

（三）聚类步骤

1. 样本集构建：将筛选后的有效样本按 BMI_{std} , Age_{std} , L_{std} , $\sigma_{V, std}$ 组成 $n \times 4$ 矩阵（ n 为样本数）；

2. K-means 迭代：

步骤 1：随机选择 K 个初始质心；

步骤 2：计算每个样本到各质心的距离，将样本归入距离最近的组；

步骤 3：更新各组质心（取组内变量均值）；

步骤 4：重复步骤 2-3，直至质心变化小于阈值（如 10^{-5} ）或迭代次数达到上限（如 100 次）；

3. 聚类有效性验证：

轮廓系数：计算每个样本的轮廓系数 $S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$ （ $a(i)$ 为

样本与组内其他样本的平均距离， $b(i)$ 为样本与最近组的平均距离），整体轮廓系数越接近 1，聚类效果越好；

组内差异检验：对每组的 BMI、年龄等变量进行单因素方差分析（ANOVA），若组间 $p < 0.01$ ，说明分组具有统计学差异。

（四）分组结果输出

1. 每组 BMI 区间确定：对每组的原始 BMI（非标准化）取最小值 $BMI_{\min}$ 和最大值 $BMI_{\max}$ ，确定区间（如组 1：[28.0,32.5)，组 2：[32.5,36.0)等），确保区间连续且无重叠；

2. 每组特征描述：统计每组的平均年龄、平均达标时间、平均检测误差、达标比例，示例如下：

表 4

聚 类 组别	BMI 区 间 (kg/m ²)	样 本 数	平 均 年 龄 (岁)	平 均 达 标 时 间 (周)	平 均 检 测 误 差 σ_v	达标比 例 R
1	[28.0,32.5)	82	29.3	13.2	0.008	0.85
2	[32.5,36.0)	75	31.5	15.7	0.012	0.72
3	[36.0,40.0)	68	33.1	18.5	0.015	0.58

4	≥ 40.0	45	34.7	21.3	0.019	0.43
---	-------------	----	------	------	-------	------

5.3.7 最佳 NIPT 时点确定：结合风险与达标比例

（一）目标函数构建

对每个聚类组，定义“风险-达标平衡指数” $F(t)$ ，选择 $F(t)$ 最小的孕周 t 作为最佳时点：

$$F(t) = \alpha \times Risk(t) + (1 - \alpha) \times (1 - R(t)) \quad (5-3-2)$$

$Risk(t)$ ：孕周 t 对应的风险系数；

$R(t)$ ：孕周 t 时的Y染色体达标比例（通过组内样本的 t 周浓度数据拟

合，如 $R(t) = \frac{1}{1 + e^{-k(t-t_0)}}$ ，Logistic 曲线拟合达标比例随孕周的增长趋势）；

α ：权重系数（ $\alpha \in [0, 1]$ ，通过临床专家意见校准，如 $\alpha = 0.6$ ，优先降低风险）。

（二）最佳时点计算步骤

1. 拟合每组的 $R(t)$ 曲线：对组内每个孕周 t ，统计浓度 $\geq 4\%$ 的样本占比，

用 Logistic 回归拟合 $R(t) = \frac{1}{1 + e^{-\beta_1(t-\beta_2)}}$ （ β_1 为增长速率， β_2 为达标比例 50%对应的孕周）；

2. 计算不同 t 的 $F(t)$ ：在临床检测窗口（10-25 周）内遍历 t （步长 0.5 周），计算每个 t 的 $F(t)$ ；

3. 确定最佳时点：取 $F(t)$ 最小值对应的 t ，若存在多个 t 对应相同最小值，选择最小的 t （尽早检测）。

（三）检测误差影响分析

1. 误差敏感性测试：对每组最佳时点 t_0 ，模拟误差扰动（如将检测误差 σ_V 增加 20%、50%），重新计算 $R(t_0)$ 和 $F(t_0)$ ；

2. 误差容忍阈值：若误差增加 50%后， $F(t_0)$ 增幅 $< 10\%$ ，说明该时点对误差不敏感；若增幅 $> 20\%$ ，需将时点后移 1-2 周，平衡误差导致的假阴性风险。

（四）分组最佳时点

基于聚类结果与目标函数计算，最终输出每组最佳时点：

表 5

聚类组别	BMI 区间	最佳 NIPT 时 点 (周)	对 应 $F(t)$	误差扰动 50% 后 $F(t)$ 增 幅
1	[28.0,32.5)	12.5	0.21	8.3%
2	[32.5,36.0)	14.0	0.35	12.1%
3	[36.0,40.0)	17.5	0.48	15.6%
4	≥ 40.0	20.0	0.62	18.9%

5.4 问题 4 的模型建立与求解

(1) 数据处理

- 数据范围：女胎检测数据（597 条），目标变量为“染色体非整倍体”（AB 列，空白=正常，非空白=异常）。
- 数据处理：编码目标变量：正常=0，异常=1；特征选择：21 号/18 号/13 号染色体 Z 值（S/R/Q 列）、GC 含量（Z/Y/X 列）、X 染色体 Z 值（T 列）、BMI（K 列）等 12 个特征；划分训练集（70%）和测试集（30%）。

(2) 变量定义：

表 6

变量类型	变量符号	变量名称	变量类型	约束条件	说明
目标变量	y	染色体非整倍体	离散	{0,1}	0=正常， 1=异常
决策变量	f_1	21 号染色体 Z 值	连续	[-3, 3]	核心特征 （唐氏综合征）
	f_2	18 号染色体 Z 值	连续	[-3, 3]	核心特征 （爱德华氏综合征）
	f_3	13 号染色体 Z 值	连续	[-3, 3]	核心特征 （帕陶氏综合征）

	$f_4 - f_{12}$	其他特征	连续 / 离散	-	GC 含量、BMI 等
中间变量	w_i	特征重要性权重	连续	[0, 1]	随机森林输出的特征权重
	T	决策树数量	整数	100 (最优参数)	随机森林参数

5.4.1 随机森林^[5]的构建

问题四需综合 12 个特征判定女胎异常，随机森林可自动捕捉特征间非线性交互，契合“多因素判定”需求；其通过抽样和随机选特征抗过拟合，适配异常样本占比低的数据特点；还能输出特征重要性，为简化临床规则提供依据，且鲁棒性强，适配 NIPT 数据实际分布

1. 决策树生成：对训练集进行有放回抽样，生成 $T' = 100$ 个样本子集；

2. 特征选择：每棵树分裂时，随机选择 $\sqrt{12} = 3$ 个特征，选择最优分裂点（Gini 指数最小）：

$$Gini(D) = 1 - \sum_{k=0}^1 p_k$$

其中 D 为样本集， p_k 为 D 中第 k 类（正常/异常）的比例；

含义：Gini 指数越小，样本纯度越高。

3. 投票决策：对测试样本，每棵树输出预测类别，最终投票多数为最终结果：

$$\hat{y} = \arg \max_{k \in \{0,1\}} \sum_{t=1}^{T'} I(h_t(x) = k) \quad (5-4-1)$$

$h_t(x)$ 为第 t 棵树的预测结果， $I(\cdot)$ 为指示函数。

5.4.2 特征重要性计算

基于“袋外误差（OOB）”计算特征 f_i 的重要性：

$$w_i = \frac{OOB \text{ 误差增加量}}{\text{所有特征误差增加量之和}} \quad (5-4-2)$$

含义：特征越重要，移除该特征后 OOB 误差上升越明显（核心特征：21 号 Z 值 $w_1 = 0.35$ ，18 号 Z 值 $w_2 = 0.25$ ）。

5.4.3 判定规则输出

根据特征重要性，简化临床判定规则：

^[5] 蔡艾廷,苏俊霖,戴昆,赵晗,王嘉义.基于长短期记忆网络和随机森林的井漏预测[J].钻井液与完井液,1-9.

1. 若 21 号 Z 值 >3.0 或 18 号 Z 值 >3.0 或 13 号 Z 值 >3.0 ，判定为“异常”；
2. 否则结合 GC 含量（若 <0.38 或 >0.42 ），判定为“可疑异常”，建议复查。
3. 结果如下：




图 6




图 7 蒙特卡洛模拟评估指标分布

由图可知，蒙特卡洛模拟的准确率均值为 97.3%——更接近模型的“真实泛化能力”。因为模型在 500 次随机数据划分下均保持高准确率和低假阳性率，不会因“某次检测的样本分布特殊”而失效，减少医疗决策风险。

结果证明：模型的高准确性不是“运气”，而是稳定的性能，可放心应用于实际 NIPT 女胎异常判定。

六、模型的评价

5-22页全部用于建模说明

6.1 模型的合理性与准确性

问题一首先通过严格数据筛选剔除异常值、整合重复数据，借助描述性统计初步观察变量关联，再逐步构建多项线性、交互性线性及多项式回归模型。其中多项式模型捕捉到孕周与 Y 染色体浓度的非线性趋势，调整后 R^2 最高，拟合优度最优，最后通过残差分析与交叉验证进一步验证其可靠性。问题二以“Y 染色体浓度 $\geq 4\%$ ”样本为基础，用 K-means 聚类结合轮廓系数保证组内同质性，构建兼顾孕周风险与准确率的风险函数，通过风险分析求解最佳时点，契合临床需求。问题三先经逐步回归筛选显著影响因素，再用 K-means 聚类（结合肘部法则与轮廓系数）确定分组，构建风险 - 达标平衡指数选取最佳时点，交叉检验与临床对比验证了模型稳健性。问题四选用随机森林处理多特征分类，分层抽样确保数据集分布一致，通过特征重要性明确核心指标，简化的判定规则便于临床应用，且测试集准确率 $\geq 90\%$ 。整体模型紧密贴合数据特征与临床实际场景，在合理性与准确性方面均表现良好。

6.2 模型的创新性

问题一突破单一线性假设，在数据预处理后逐步构建多项线性、交互性线性模型，最终引入二次项构建多项式回归模型，精准捕捉孕周与 Y 染色体浓度的

“边际递减”非线性关系，同时纳入 BMI 交互效应，提升变量关系刻画深度。问题二将 K-means 聚类与风险优化结合，以轮廓系数保障分组同质性，通过加权整合孕周风险与检测准确率构建风险函数，实现“分组 - 选点”一体化优化，贴合临床“尽早检测 + 结果准确”需求。问题三在问题二基础上，先经逐步回归筛选身高、年龄等显著影响因素，再结合检测误差与达标比例优化聚类变量，构建风险 - 达标平衡指数，兼顾多因素与临床风险分层，增强模型实用性。问题四选用随机森林处理多特征分类，通过袋外误差计算特征重要性，明确核心判定指标并简化临床规则，相比传统逻辑回归更能捕捉特征非线性交互，提升女胎异常判定的可操作性与准确性。

6.3 模型的局限性

问题一多项式回归未充分考虑孕妇年龄、测序读段数等潜在影响因素，且依赖线性假设与正态残差分布，对极端 BMI 样本适应性较弱。问题二 K-means 聚类易受初始质心影响，且仅以 BMI 分组，未纳入检测误差外的其他个体差异，风险函数中权重系数依赖临床经验赋值，主观性较强。问题三虽整合多因素，但逐步回归可能遗漏非线性关联变量，且检测误差仅以标准差量化，未考虑系统误差对结果的影响，风险 - 达标平衡指数的权重校准缺乏大规模临床数据支撑。问题四随机森林模型对小样本异常数据敏感，简化判定规则未涵盖 GC 含量异常与染色体 Z 值的复杂交互情况，且未验证模型在不同地区孕妇群体中的适用性。

6.4 结论

围绕 NIPT 时点选择与胎儿异常判定问题，经系列模型分析形成如下结论：问题一构建的多项式回归模型，精准描绘出孕周与 Y 染色体浓度的“边际递减”非线性关联，同时体现 BMI 的调节作用，为后续研究奠定变量关系基础；问题二借助 K-means 聚类对男胎孕妇 BMI 进行合理分组，结合风险函数确定各组最佳 NIPT 检测时点，实现检测及时性与准确性的平衡；问题三在整合身高、年龄等多因素及检测误差后，进一步优化分组与时点选择，有效降低潜在风险；问题四采用随机森林模型，明确 21 号、18 号等染色体 Z 值是女胎异常判定的核心指标，简化后的临床规则可高效辅助女胎异常判定。各模型结果均契合临床实际需求，为 NIPT 检测工作提供科学参考依据。

七、模型的检验与结论

7.1 模型的检验

7.1.1 问题一整体显著性检验

1. 残差分析：绘制多项式回归模型的残差图（残差-拟合值、残差-QQ 图），验证残差是否服从正态分布、方差齐性，若残差随机分布无明显规律，说明模型满足假设条件。




图 8 多项式回归模型残差分析

左图可以看出模型的假设是正确的，右图可以证明模型的误差来源是随机的，不是系统性错误。

这张图是“模型的合格证书”，点越乱、越靠近直线，说明模型越靠谱，后续用它预测才可信。

2. 交叉验证：采用 K 折交叉验证 ($K=5$)，将数据分为 5 组，轮流用 4 组训练模型、1 组验证，计算平均预测误差（如 MSE），若 MSE 较小且稳定，说明模型泛化能力强。




图 9 5 折交叉验证 MSE 比较

有图可以看出，多项式模型最能精准预测 Y 染色体浓度。

7.1.2 问题二

（一）内部验证：交叉检验

1. 样本分割：将总样本按 7:3 划分为训练集（用于建模）和验证集（用于验证）；
2. 模型复现：在训练集上重复逐步回归与聚类分析，得到分组与最佳时点；
3. 验证指标：计算验证集样本的“实际达标比例”与模型预测 $R(t_0)$ 的偏差（ $\Delta R = |R_{\text{实际}} - R_{\text{预测}}|$ ），若 $\Delta R < 0.1$ 的样本占比 > 80%，说明模型稳健。

（二）外部验证：临床数据对比

将模型输出的最佳时点与临床经验时点（如题目建议的[20,28)组 12 周、[36,40)组 18 周）对比，若模型时点与临床时点偏差 < 2 周，且模型对应的达标比例更高（如模型组 3 时点 17.5 周达标比例 58%，临床 18 周达标比例 55%），说明模型更优。

（三）异常值影响测试

剔除 10% 的极端 BMI 样本（如 BMI > 45），重新建模，若分组区间与最佳时点变化 < 1 周，说明模型对异常值稳健。

7.2 结论

7.2.1 问题一的结论

1. 模型选择：通过三个模型的比对和层层递进，得出多项式回归模型的拟合优度和解释力最优，可作为 Y 染色体浓度与孕周、BMI 关系的核心模型。
2. 变量关系：

孕周与 Y 染色体浓度呈显著正相关，且增长趋势为二次曲线（边际递减）；BMI 通过直接效应（负相关）和交互效应（削弱孕周的正向影响），显著延缓 Y 染色体浓度增长，BMI 越高，达标时间越晚。




图 10 三维散点图与拟合曲面（多项式回归）

- 彩色散点：是真实的检测数据，每个点代表一位妈妈的“孕周 - BMI-Y 浓度”实际情况，比如某个点在（14 周，28BMI，4.2%），说明这位妈妈 14 周、BMI28 时，Y 浓度达标了。
- 半透明曲面：是模型预测的“趋势地形”，比如曲面在“孕周大、BMI 小”的区域（X 大、Y 小）Z 值高（Y 浓度高），在“孕周小、BMI 大”的区域 Z 值低，就像“3D 地图上的高地和洼地”，想让 Y 浓度达标，最好选“孕周稍大、BMI 不高”的组合。

7.2.2 问题二的结论

通过“K-means 聚类 + 风险优化”模型，成功实现了“基于 BMI 的精准分组”与“时点个性化推荐”，结果符合题目“BMI 为主要因素”“风险最小化”的核心要求。从临床应用角度，该结果可直接用于高 BMI 孕妇群体的 NIPT 检测指导——通过简单的 BMI 匹配分组，即可快速确定最佳检测时点，同时针对高敏感组（第 3、4 组）提出误差控制建议，兼顾了“科学性”与“实用性”。

7.2.3 问题三的结论

1. 分组结果：明确 4 组 BMI 区间及每组的核心特征（年龄、检测误差、达标比例）；
2. 最佳时点：给出每组的最佳 NIPT 检测孕周，及其对检测误差的容忍度；
3. 决策建议：对高 BMI 组（如 ≥ 40.0 ），建议增加测序深度（提高总读段数）以降低检测误差，或在最佳时点后 1 周复查，确保结果准确性。

7.2.4 问题四的结论

蒙特卡洛模拟^[6]的准确率均值为 97.3%，证明：模型的准确性高、稳定性强，可放心应用于实际 NIPT 女胎异常判定。

八、参考文献

- [1] 薛莹,丁洁,贺权泽,王挺.孕妇年龄、孕周及体重指数对孕妇外周血中胎儿游离 DNA 比例的影响[J].中国产前诊断杂志(电子版),2017,9(03):5-10.
- [2] 吕远,于文倩,尹少尉,刘彩霞.双胎妊娠胎儿游离 DNA 比例及其影响因素研究[J].中国实用妇科与产科杂志,2016,32(11):1117-1120.
- [3] 李燕,熊卫云,陈军,姚小康,尹昭,王天朝.医疗风险预警系统的构建[J].卫生软科学,2011,25(08):584-586.
- [4] 张昊,史小红,卢俊平,全栋,刘禹,郭鑫.基于 ARIMA 模型和多元逐步回归模型的查干淖尔叶绿素 a 浓度模拟与预测[J].水生态学杂志,1-11.
- [5] 蔡艾廷,苏俊霖,戴昆,赵晗,王嘉义.基于长短期记忆网络和随机森林的井漏预测[J].钻井液与完井液,1-9.
- [6] 许旭平.母体血浆中胎儿游离 DNA 定量及其在无创产前筛查中的应用研究[D].南方医科大学, 2016.
- [7] DeepSeek, DeepSeek-V3.1, 深度求索 (DeepSeek), 2025-09-05
- [8] DeepSeek, DeepSeek-V3.1, 深度求索 (DeepSeek), 2025-09-05

^[6] 许旭平.母体血浆中胎儿游离 DNA 定量及其在无创产前筛查中的应用研究[D].南方医科大学, 2016.

附录

附录 1

介绍：关于三个模型的拟合效果比较

%% 第一问数据预处理与修改

```
clear; clc; close all;
```

%% 1. 读取附件数据

% 方法 1: 使用工作表索引或名称

```
yqh = readtable('附件.xlsx', 'Sheet', '男胎检测数据');
```

% 检查所有列名是否读取正确

```
disp('Excel 表格列名:');
```

```
disp(yqh.Properties.VariableNames);
```

%% 2. 对附件数据进行预处理

% 2.1 借助索引来得到关键数据

% 先检查列名，确保我们提取正确的列

```
szz = yqh.Properties.VariableNames;
```

```
disp('列名列表:');
```

```
for i = 1:length(szz)
```

```
    fprintf('%d: %s\n', i, szz{i});
```

```
end
```

%表示索引对应数据：样本序号，孕妇代码，孕妇年龄，孕妇身高，孕妇体重

```
sample_id = yqh{:, 1};
```

```

whr = yqh{:, 2};
xym = yqh{:, 3};
lck = yqh{:, 4};
wmj = yqh{:, 5};
fj = yqh{:, 10}; % 检测孕周
bmi = yqh{:, 11}; % 孕妇 BMI
lyq = yqh{:, 22}; % Y 染色体浓度
xrstnd = yqh{:, 23}; % X 染色体浓度

% 2.2 将孕周格式转换成 11.86 周类型
rjf = size(yqh, 1); % 检查输入类型
ylp = zeros(rjf, 1);
% 处理包含周和天的数据
for i = 1:rjf
    if iscell(fj)
        lzp = fj{i};
    else
        lzp = fj(i);
    end

    if ischar(lzp) || isstring(lzp)
        lzp = char(lzp);
        if contains(lzp, 'w+')
            zy = strsplit(lzp, 'w+');
            hjh = str2double(zy{1});
            xht = str2double(zy{2});
        end
    end
end

```

```

        if ~isnan(hjh) && ~isnan(xht)

            ylp(i) = hjh + xht/7;

        end

        %处理只含周的数据

        elseif contains(lzp, 'w')

            lxx = regexp(lzp, '\d+', 'match');

            if ~isempty(lxx)

                hjh = str2double(lxx{1});

                if ~isnan(hjh)

                    ylp(i) = hjh;

                end

            end

        end

    end

end

end

end

% 2.3 数据筛选

% 按照约束条件处理数据

nba = (ylp >= 10 & ylp <= 25) & ...%孕周

        (~isnan(lyq) & lyq > 0) & ...%Y 染色体浓度

        (~isnan(xrstnd) & xrstnd > 0) & ...

        (bmi >= 18.5 & bmi <= 45);%bmi

%将处理后的数据弄成表

mdh = table(whr(nba), xym(nba), lck(nba), ...

            wmj(nba), ylp(nba), bmi(nba), ...

```

```

        lyq(nba), xrstnd(nba), ...

        'VariableNames', {'PregnantCode', 'Age', 'Height', 'Weight',
'GestationalWeek', 'BMI', 'YChromosomeConc', 'XChromosomeConc'}));

% 2.4 采用箱线图法进行异常值处理
% 按孕妇代码分组处理异常值
txz = unique(mdh.PregnantCode);
yxx = table();

for i = 1:length(txz)
    ly = txz{i};
    qxh = strcmp(mdh.PregnantCode, ly);
    hby = mdh(qxh, :);

    if size(hby, 1) > 0
        % 计算 Y 染色体浓度的四分位数
        qone = prctile(hby.YChromosomeConc, 25);
        qthree = prctile(hby.YChromosomeConc, 75);
        rqiop = qthree - qone;
        lboun = qone - 1.5 * rqiop;
        uboun = qthree + 1.5 * rqiop;

        % 将异常值去掉
        dx1 = (hby.YChromosomeConc >= lboun) & (hby.YChromosomeConc <=
uboun);
        hby = hby(dx1, :);
    end
end

```

```

        % 添加到清洁数据

        yxx = [yxx; hby];

    end
end

% 2.5 对于重复的数据取均值处理
% 对同一孕妇的数据取平均值
[jyh, ~, ic] = unique(yxx.PregnantCode);
lxy = table();

for i = 1:length(jyh)

    llt = (ic == i);

    hby = yxx(llt, :);

    % 算出均值

    sjy = varfun(@mean, hby, 'InputVariables', {'Age', 'Height', 'Weight',
'GestationalWeek', 'BMI', 'YChromosomeConc', 'XChromosomeConc'});

    sjy.PregnantCode = jyh(i);

    % 对于均值重新排序

    sjy = sjy(:, [end, 1:end-1]);

    lxy = [lxy; sjy];

end

% 2.6 依照 bmi 分组
% 先采取等距五分法将 bmi 分组
pyq = [18.5, 25, 30, 35, 40, 45];

```



```

lyx = discretize(lxy.mean_BMI, pyq);
lxy.BMIGroup = lyx;

% 2.7 将处理后数据存下来
writetable(lxy, 'chuliwenjian.xlsx');
disp('数据预处理完成，结果已保存到 chuliwenjian.xlsx');

%% 3. 描述性统计分析 - 直方图

% 绘制 bmi 与 Y 染色体浓度的关系直方图
figure('Position', [100, 100, 1200, 800]);
whj = {'18.5-25', '25-30', '30-35', '35-40', '40-45'};

% 保证 Y 轴的单位与系数统一
wwl = [];
for i = 1:5
    xch = lxy(lxy.BMIGroup == i, :);

    % 创建孕周区间
    wbbin = 10:1:25;

    [N, edges] = histcounts(xch.mean_GestationalWeek, wbbin);

    % 计算每个区间的 Y 染色体浓度平均值
    cms = zeros(1, length(edges)-1);

    for j = 1:length(edges)-1
        bdxx = (xch.mean_GestationalWeek >= edges(j)) &
(xch.mean_GestationalWeek < edges(j+1));%创建出逻辑索引来筛选样本

```

```

        if any(bdxx)
            cms(j) = mean(xch.mean_YChromosomeConc(bdxx));
        else
            cms(j) = NaN;
        end
    end
end

wwl = [wwl, cms(~isnan(cms))];%添加结果变量
end

% 确定统一的 Y 轴范围
minY = floor(min(wwl) * 10) / 10;
MAXy = ceil(max(wwl) * 10) / 10;
if minY == MAXy
    MAXy = minY + 0.1;
end

for i = 1:5
    subplot(2, 3, i);

    xch = lxy(lxy.BMIGroup == i, :);

    % 创建孕周区间
    wbbin = 10:1:25;

    [N, edges] = histcounts(xch.mean_GestationalWeek, wbbin);

    % 计算每个区间的 Y 染色体浓度平均值
    cms = zeros(1, length(edges)-1);

```

```

for j = 1:length(edges)-1

    bdxx = (xch.mean_GestationalWeek >= edges(j)) &
(xch.mean_GestationalWeek < edges(j+1));%通过索引来获取各个区间的样本数据

    if any(bdxx)

        cms(j) = mean(xch.mean_YChromosomeConc(bdxx));%计算出 Y 染色体平均浓度

    else

        cms(j) = NaN;

    end

end

% 绘制出所需直方图

x_edges = edges(1:end-1);

bar(x_edges, cms, 'hist');

hold on;

% 添加趋势线

nba = ~isnan(cms);%识别非 NAN 数据点

if sum(nba) > 1

    p = polyfit(x_edges(nba), cms(nba), 1); %进行线性拟合

    tx = linspace(min(x_edges(nba)), max(x_edges(nba)), 100);

    trend_y = polyval(p, tx);

    plot(tx, trend_y, 'r-', 'LineWidth', 2);%绘制趋势线

end

% 添加达标线（4%）

yline(4, '--g', '达标线 (4%)', 'LineWidth', 1.5, 'FontSize', 10);

```

```

        title(sprintf('BMI 分组: %s\n 样本数量: %d', whj{i}, size(xch, 1)), 'FontSize', 12);
        xlabel('孕周', 'FontSize', 11);
        ylabel('Y 染色体浓度平均值 (%)', 'FontSize', 11);

        grid on;

        xlim([10, 25]);

        ylim([minY, MAXy]); % 统一 Y 轴范围

        set(gca, 'FontSize', 10);
    end

% 添加总标题
sgtitle('不同 BMI 分组下 Y 染色体浓度随孕周变化趋势', 'FontSize', 16, 'FontWeight',
'bold');

saveas(gcf, 'Y_chromosome_concentration_by_gestational_week.png');

%% 4. 回归模型建立与显著性检验

% 准备数据
X1 = lxy.mean_GestationalWeek; % 孕周
X2 = lxy.mean_BMI; % BMI
Y = lxy.mean_YChromosomeConc; % Y 染色体浓度

% 4.1 多项线性回归模型
xlin = [ones(length(X1), 1), X1, X2];
[blin, bint_linear, r_linear, rint_linear, slin] = regress(Y, xlin);

disp('=== 多元线性回归结果 ===');

```

```

disp(['系数:  $\beta_0 =$  ', num2str(blin(1)), ',  $\beta_1 =$  ', num2str(blin(2)), ',  $\beta_2 =$  ',
num2str(blin(3))]);

disp(['R2 = ', num2str(slin(1)), ', F 值 = ', num2str(slin(2)), ', p 值 = ',
num2str(slin(3))]);

% 4.2 交互性线性回归模型
% 对自变量进行中心化处理, 减少多重共线性

xce = X1 - mean(X1);
xcen = X2 - mean(X2);
xeen = xce .* xcen;

xin = [ones(length(X1), 1), xce, xcen, xeen];%构建线性矩阵
[bter, bint_inter, r_inter, rint_inter, ster] = regress(Y, xin); %执行回归分析

disp('=== 交互性线性回归结果 ==='); %展示回归结果

disp(['系数:  $\beta_0 =$  ', num2str(bter(1)), ',  $\beta_1 =$  ', num2str(bter(2)), ',  $\beta_2 =$  ',
num2str(bter(3)), ',  $\beta_3 =$  ', num2str(bter(4))]);

disp(['R2 = ', num2str(ster(1)), ', F 值 = ', num2str(ster(2)), ', p 值 = ',
num2str(ster(3))]);

% 4.3 多项式回归模型
spqowi = xce.^2;%计算二次项
xpoy = [ones(length(X1), 1), xce, spqowi, xcen, xeen];
[boiy, bint_poly, r_poly, rint_poly, soly] = regress(Y, xpoy);

disp('=== 多项式回归结果 ===');%将回归结果显示出来

disp(['系数:  $\beta_0 =$  ', num2str(boiy(1)), ',  $\beta_1 =$  ', num2str(boiy(2)), ',  $\beta_2 =$  ',
num2str(boiy(3)), ...

```

```

        ',  $\beta_3$  = ', num2str(boiy(4)), ',  $\beta_4$  = ', num2str(boiy(5))]);
disp(['R2 = ', num2str(soly(1)), ', F 值 = ', num2str(soly(2)), ', p 值 = ',
num2str(soly(3))]);

%% 5. 可视化：散点图矩阵与 Y 染色体浓度解析

% 5.1 散点图矩阵
figure('Position', [100, 100, 1000, 800]);
cbt = [X1, X2, Y];
zqc = {'孕周', 'BMI', 'Y 染色体浓度'};
plotmatrix(cbt);
for i = 1:3
    for j = 1:3
        subplot(3, 3, (i-1)*3+j);%选择对应子图位置
        if i == j
            histogram(cbt(:, i), 20);
            title(zqc{i}, 'FontSize', 12);
        else
            scatter(cbt(:, j), cbt(:, i), 10, 'filled');
        end
        set(gca, 'FontSize', 10);%设计当前子图字体大小
    end
end
sgtitle('变量散点图矩阵', 'FontSize', 16, 'FontWeight', 'bold');
saveas(gcf, 'scatter_plot_matrix.png');%保存图片

% 5.2 生成三个方向的截面图

```

```

figure('Position', [100, 100, 1200, 400]);

% 固定 BMI，查看 Y 染色体浓度与孕周的关系
subplot(1, 2, 1);

bmiqu = quantile(X2, [0.25, 0.5, 0.75]);
colors = ['r', 'g', 'b'];
labels = {'低 BMI (25%)', '中 BMI (50%)', '高 BMI (75%)'};

for i = 1:3
    bvali = bmiqu(i);
    qxh = (X2 >= bvali*0.9 & X2 <= bvali*1.1); % 选择接近该分位数的数据

    if sum(qxh) > 5 % 确保有足够的数据点
        scatter(X1(qxh), Y(qxh), 30, colors(i), 'filled');
        hold on;

        % 添加趋势线
        p = polyfit(X1(qxh), Y(qxh), 1);
        rangexx = linspace(min(X1(qxh)), max(X1(qxh)), 100);
        fity = polyval(p, rangexx);
        plot(rangexx, fity, 'Color', colors(i), 'LineWidth', 2, 'DisplayName', labels{i});
    end
end

title('固定 BMI 下 Y 染色体浓度与孕周关系', 'FontSize', 12);
xlabel('孕周', 'FontSize', 11);

```

```

ylabel('Y 染色体浓度 (%)', 'FontSize', 11);

legend('show', 'FontSize', 10);

grid on;

set(gca, 'FontSize', 10);

% 固定孕周，查看 Y 染色体浓度与 BMI 的关系

subplot(1, 2, 2);

wqsss = quantile(X1, [0.25, 0.5, 0.75]);

for i = 1:3

    wvalll = wqsss(i);

    qxh = (X1 >= wvalll*0.9 & X1 <= wvalll*1.1); % 选择接近该分位数的数据

    if sum(qxh) > 5 % 确保有足够的数据点

        scatter(X2(qxh), Y(qxh), 30, colors(i), 'filled');%绘制散点图

        hold on;

        % 添加趋势线

        p = polyfit(X2(qxh), Y(qxh), 1);

        rangexx = linspace(min(X2(qxh)), max(X2(qxh)), 100);

        fity = polyval(p, rangexx);

        plot(rangexx, fity, 'Color', colors(i), 'LineWidth', 2, 'DisplayName', labels{i});

    end

end

end

title('固定孕周下 Y 染色体浓度与 BMI 关系', 'FontSize', 12);

```



```

xlabel('BMI', 'FontSize', 11);
ylabel('Y 染色体浓度 (%)', 'FontSize', 11);
legend('show', 'FontSize', 10);
grid on;
set(gca, 'FontSize', 10);

sgtitle('Y 染色体浓度截面分析', 'FontSize', 16, 'FontWeight', 'bold');
saveas(gcf, 'cross_sectional_views.png');

%% 6. 对于此模型的显著性检验与残差分析

% 6.1 残差分析
figure('Position', [100, 100, 1200, 400]);

% 残差与拟合值图
subplot(1, 2, 1);
pioypred = xpoy * boiy;
scatter(pioypred, r_poly, 30, 'filled');
hold on;
yline(0, '--r', 'LineWidth', 1.5);
title('残差与拟合值图（多项式模型）', 'FontSize', 12);
xlabel('拟合值', 'FontSize', 11);
ylabel('残差', 'FontSize', 11);
grid on;
set(gca, 'FontSize', 10);

```

```

% 残差正态概率图

subplot(1, 2, 2);
normplot(r_poly);
title('残差正态概率图（多项式模型）', 'FontSize', 12);
set(gca, 'FontSize', 10);

sgtitle('多项式回归模型残差分析', 'FontSize', 16, 'FontWeight', 'bold');
saveas(gcf, 'residual_analysis.png');

% 6.2 交叉验证，设立五组数据，分别进行训练和测试
rng(42); % 设置随机种子以确保可重复性
cv = cvpartition(length(Y), 'KFold', 5);
mlin = zeros(5, 1);
mter = zeros(5, 1);
mpoly = zeros(5, 1);

for i = 1:5
    % 分割训练集和测试集
    xltrain = training(cv, i);
    ctest = test(cv, i);

    % 多项线性回归
    %提取训练特征以及进行训练
    xtriner = xlin(xltrain, :);
    ytriner = Y(xltrain);
    btriner = regress(ytriner, xtriner);

```

```

%提取测试特征并进行测试

xtester = xlin(cstest, :);

ytester = Y(cstest);

ypreder = xtester * btriner;

mlin(i) = mean((ytester - ypreder).^2);


% 交互性线性回归（步骤同上）

pqowie = xin(xltrain, :);

laksjd = regress(ytriner, pqowie);


zmxncb = xin(cstest, :);

qlaowk = zmxncb * laksjd;

mter(i) = mean((ytester - qlaowk).^2);


% 多项式回归（步骤同上）

zkaiqmj = xpoy(xltrain, :);

qazwsx = regress(ytriner, zkaiqmj);


pioytest = xpoy(cstest, :);

pioypred = pioytest * qazwsx;

mpoly(i) = mean((ytester - pioypred).^2);

end


%绘制测试结果评分图

disp('=== 5 折交叉验证结果 ===');

```

```

disp(['多元线性回归平均 MSE: ', num2str(mean(mlin))]);
disp(['交互性线性回归平均 MSE: ', num2str(mean(mter))]);
disp(['多项式回归平均 MSE: ', num2str(mean(mpoly))]);

% 绘制交叉验证结果

figure;
boxplot([mlin, mter, mpoly], 'Labels', {'线性', '交互', '多项式'});
ylabel('均方误差 (MSE)', 'FontSize', 11);
title('5 折交叉验证 MSE 比较', 'FontSize', 14, 'FontWeight', 'bold');
set(gca, 'FontSize', 10);
saveas(gcf, 'cross_validation_mse.png');

%% 7. 三个模型的比较与选择

% 计算调整  $R^2$ 
nnn = length(Y);
pliners = 2; % 线性模型参数个数（除截距外）
pinters = 3; % 交互模型参数个数
ppolys = 4; % 多项式模型参数个数

% 计算各个模型调整后的  $R^2$ 
adjliners = 1 - (1-slin(1)) * (nnn-1)/(nnn-pliners-1);
adjinters = 1 - (1-ster(1)) * (nnn-1)/(nnn-pinters-1);
adjpolys = 1 - (1-soly(1)) * (nnn-1)/(nnn-ppolys-1);

disp('=== 模型比较 ===');

```

```

disp(['多元线性回归调整 R2 : ', num2str(adjliners)]);
disp(['交互性线性回归调整 R2 : ', num2str(adjinters)]);
disp(['多项式回归调整 R2 : ', num2str(adjpolys)]);

% 根据调整 R2 选择最佳模型

[~, best] = max([adjliners, adjinters, adjpolys]);
model_names = {'多元线性回归', '交互性线性回归', '多项式回归'};
disp(['最佳模型: ', model_names{best}]);

%% 8. 结果可视化 - 选出最佳模型：三维散点图与拟合曲面

% 使用最佳模型（多项式回归）绘制拟合曲面
figure('Position', [100, 100, 800, 600]);

% 创建网格数据
rangexx = linspace(min(X1), max(X1), 20);
rangexxx = linspace(min(X2), max(X2), 20);
[xgridd, xgridi] = meshgrid(rangexx, rangexxx);

% 中心化
X1_grid_centered = xgridd - mean(X1);
X2_grid_centered = xgridi - mean(X2);

% 计算预测值
ygridd = boiy(1) + boiy(2)*X1_grid_centered + boiy(3)*X1_grid_centered.^2 + ...
        boiy(4)*X2_grid_centered + boiy(5)*X1_grid_centered.*X2_grid_centered;

```

```

% 绘制三维散点图

scatter3(X1, X2, Y, 30, Y, 'filled');

hold on;

% 绘制拟合曲面

surf(xgridd, xgridd, ygridd, 'FaceAlpha', 0.5, 'EdgeColor', 'none');

colormap(jet);

colorbar;

xlabel('孕周', 'FontSize', 12);

ylabel('BMI', 'FontSize', 12);

zlabel('Y 染色体浓度 (%)', 'FontSize', 12);

title('三维散点图与拟合曲面（多项式回归）', 'FontSize', 14, 'FontWeight', 'bold');

grid on;

set(gca, 'FontSize', 10);

saveas(gcf, '3d_scatter_fitted_surface.png');

disp('分析完成！所有结果已保存为图像文件。');

```

附录 2

介绍：问题 2：利用风险分析解决最佳时点预测问题

%% 问题 2：K-means 聚类+BMI 分组+风险分析

```
clear; clc; close all;
```

```
%% 1. 读取与预处理初始数据
```

```
% 读取 Excel 文件
```

```
data = readtable('附件.xlsx');

% 使用索引将数据表明
yqh = data{:, 1};
szz = data{:, 2};
age = data{:, 3};
height = data{:, 4};
weight = data{:, 5};
whr = data{:, 10};
xym = data{:, 11}; % 使用所有 BMI 数据
lck = data{:, 22};

% 转换检测孕周的格式
wmj = zeros(size(data, 1), 1);
for i = 1:size(data, 1)
    fj = whr{i};

    % 得到所有数字，方便后续计算
    ylp = regexp(fj, '\d+', 'match');

    if length(ylp) >= 1 %检查是否有元素
        lyq = str2double(ylp{1});
        if length(ylp) >= 2
            rjf = str2double(ylp{2});
        else
            rjf = 0;
```

```

        end

        wmj(i) = lyq + rjf/7; %计算总周数
    else
        % 如果无法解析， 设置为 NaN

        wmj(i) = NaN;

        warning('无法解析孕周字符串: %s', fj);
    end
end

% 检测如果包含了 NAN， 则直接移除
zy = ~isnan(wmj);
data = data(zy, :);
wmj = wmj(zy);
xym = xym(zy);
lck = lck(zy);
szz = szz(zy);

% 对于每个孕妇， 使用其第一次检测的数据
[hjh, ~, ic] = unique(szz);
xht = zeros(length(hjh), 1);
ljx = zeros(length(hjh), 1);

for i = 1:length(hjh)
    mdh = find(ic == i);
    % 获取第一次检测的数据
    xht(i) = xym(mdh(1));
end

```



```

    lxx(i) = wmj(mdh(1));
end

% 使用第一次检测的数据作为分析样本

bmi = xht;
t0 = lxx;
n = length(bmi);

%% 2. 将参数完成初始化
tzx = 4; % 聚类数
yxx = 0.6; % 孕周风险权重（根据临床建议：尽早检测更重要，所以设  $\alpha > 0.5$ ）
jyh = 1 - yxx; % 准确率风险权重
lxy = 10:0.5:25; % 枚举的检测时点范围

%% 3. 开始使用模型
% 步骤 1：K-means 聚类，根据 bmi 标准分组
llt = zscore(bmi);
[mdh, centers] = kmeans(llt, tzx); % 表明样本聚类标签，标准化聚类中心

% 步骤 2：得到平均达标孕周
j0t = zeros(tzx, 1);
for j=1:tzx
    j0t(j) = mean(t0(mdh==j)); % 用 mean 而非 sum/n，保证除法不出问题
end

% 步骤 3：风险优化，采用枚举法

```

```

tbest = zeros(tzx,1);
riskmin = zeros(tzx,1);
sjy = zeros(tzx, length(lxy)); % 存储每组各时点的风险

for j=1:txz
    for k=1:length(lxy)
        xqx = lxy(k);
        % 孕周风险 R 分组
        if xqx <= 12
            pyq = 0.2;
        elseif xqx <= 27
            pyq = 0.6;
        else
            pyq = 1.0;
        end
        % 准确率风险，判断什么时候准确率高，风险低
        if xqx >= j0t(j)
            lyx = 0.1;
        else
            lyx = 1.0 - 0.09*(xqx/j0t(j)); % 突出线性相关，向下趋势
        end
        sjy(j,k) = yxx*pyq + jyh*lyx;
    end
    % 找出风险最小时的最佳时点
    [riskmin(j),idx_min ] = min(sjy(j,:));
    tbest(j) = lxy(idx_min);
end

```

```

end

% 步骤 4: 将 bmi 区间根据聚类修改拟合

wwl = centers*std(bmi) + mean(bmi); % 标准化逆变换

% 排序聚类中心, 确定 BMI 区间

[xch, idx_sort] = sort(wwl);

wsm = zeros(tzx,2);

for j=1:txz

    if j == 1

        wsm(j,1) = min(bmi); % 找出 bmi 下界

    else

        wsm(j,1) = (xch(j-1) + xch(j))/2; % 区间中点为边界

    end

    if j == txz

        wsm(j,2) = max(bmi); % 找出 bmi 上界

    else

        wsm(j,2) = (xch(j) + xch(j+1))/2;

    end

end

end

%% 4. 将结果输出

fprintf('\n===== 问题 2: BMI 分组与最佳检测时点 =====\n');

fprintf('风险权重:  $\alpha$  (孕周风险)=%.1f,  $\beta$  (准确率风险)=%.1f\n', yxx, jyh);

fprintf('分组结果: \n');

for j=1:txz

    fprintf('第%d 组: BMI=[%.1f, %.1f) kg/m2, 平均达标孕周=%.1f 周, 最佳检测  
时点=%.1f 周, 最小风险=%.3f\n',...

```

```

        j, wsm(j,1), wsm(j,2), j0t(idx_sort(j)), tbest(idx_sort(j)), riskmin(idx_sort(j)));
end

%% 5. 完成答案的可视化

figure('Position', [100,100,1200,600]);

subplot(2,2,1);% 子图 1: BMI 聚类结果

colors = lines(tzx);% 创建颜色映射
colormap(colors);
scatter(bmi, t0, 30, mdh, 'filled');

hold on;

for j=1:txz
    plot(wwl(j), j0t(j), 'ko', 'MarkerSize', 10, 'LineWidth', 2); % 聚类中心
    text(wwl(j)+0.5, j0t(j), sprintf('组%d', j), 'FontSize', 12);
end

xlabel('BMI (kg/m?) '); ylabel('首次检测孕周 (周) '); title('BMI 聚类结果 (颜色区
分组别, 黑圈为中心) ');

grid on; legend('样本', '聚类中心');

% 子图 2: 每组风险曲线

subplot(2,2,2);

colors = ['r', 'g', 'b', 'm'];

for j=1:txz
    plot(lxy, sjy(idx_sort(j),:), colors(j), 'LineWidth', 2);

    hold on;

    plot(tbest(idx_sort(j)), riskmin(idx_sort(j)), [colors(j) 'o'], 'MarkerSize', 8,

```

```

'LineWidth', 2);%标记最佳时点

    text(tbest(idx_sort(j))+0.5, riskmin(idx_sort(j)), sprintf(' 组 %d', j), 'FontSize',
10);%给每个组别添加标签

end

xlabel('检测时点（周）'); ylabel('综合风险'); title('各组风险曲线（圆点为最佳时点）');

grid on; ylim([0, 0.8]);

% 子图 3: BMI 分组区间柱状图

subplot(2,2,3);

bar(1:tzx, wsm(:,2)-wsm(:,1), 'FaceColor', [0.53, 0.81, 0.98], 'EdgeColor', 'black'); %弄
好条形图

xlabel('分组'); ylabel('BMI 区间宽度（kg/m2）'); title('各组 BMI 区间宽度');

xticklabels({sprintf('%.1f,%.1f)', wsm(1,1), wsm(1,2)),...

    sprintf('%.1f,%.1f)', wsm(2,1), wsm(2,2)),...

    sprintf('%.1f,%.1f)', wsm(3,1), wsm(3,2)),...

    sprintf('%.1f,%.1f)', wsm(4,1), wsm(4,2))});

xtickangle(45); grid on;%旋转 x 轴并设置好网格

% 子图 4: 最佳时点分布

subplot(2,2,4);

% 修改颜色设置，使用 RGB 值代替颜色名称

bar(1:tzx, tbest(idx_sort), 'FaceColor', [0.94, 0.5, 0.5], 'EdgeColor', 'black');

xlabel('分组'); ylabel('最佳检测时点（周）'); title('各组最佳检测时点');

xticklabels({sprintf('组 1\nBMI[%.1f,%.1f]', wsm(1,1), wsm(1,2)),...

    sprintf('组 2\nBMI[%.1f,%.1f]', wsm(2,1), wsm(2,2)),...%将 X 轴的刻度确定好

    sprintf('组 3\nBMI[%.1f,%.1f]', wsm(3,1), wsm(3,2)),...

```

```

    sprintf('组 4\nBMI[%.1f,%.1f]', wsm(4,1), wsm(4,2)));
xtickangle(0); grid on; ylim([10, 20]);

% 保存图像
saveas(gcf, '问题 2_聚类优化结果.png');

% 额外分析：Y 染色体浓度与 BMI 的关系（使用所有数据）
figure;
scatter(xym, lck, 30, 'filled');%绘制散点图
xlabel('BMI (kg/m^2)');
ylabel('Y 染色体浓度');
title('Y 染色体浓度与 BMI 的关系');%添加图像标题
grid on;%添加网格线
correlation = corr(xym, lck);
text(mean(xym), mean(lck), sprintf('相关系数: %.3f', correlation), 'FontSize', 12);%将
相关系数文本添加上去
saveas(gcf, 'Y 染色体浓度与 BMI 的关系.png');

```

附录 3

介绍：多因素干扰下 NIPT 最佳时点选择

```

clc;
clear;
close all;

%% 1. 读取附件中的数据
% 读取附件
shuju = readtable('附件.xlsx');

```

```

% 借助索引完成数据标识： A 列 - 样本序号，B 列 - 孕妇代码，C 列 - 年龄
ybxh = shuju{:, 1};
yfdm = shuju{:, 2};
nl = shuju{:, 3};
sg = shuju{:, 4};           %D 列 身高
kg = shuju{:, 5};           % E 列 体重
yunzhou_str = shuju{:, 10}; % J 列 孕周
imb = shuju{:, 11};          % K 列 BMI
yrstnd = shuju{:, 22}; % V 列 Y 染色体浓度
yscxzds = shuju{:, 12};      % L 列 原始测序总读数
ckjybdbl = shuju{:, 13};     % M 列 参考基因组比对比例
gc = shuju{:, 16};           % P 列 GC 含量

% 转换孕周的数值格式，方便后续处理
yqh = zeros(size(yunzhou_str));
for i = 1:length(yunzhou_str)
    if iscell(yunzhou_str)
        szz = yunzhou_str{i};
    else
        szz = yunzhou_str(i);
    end

    % 得到相应的天数与周数
    whr = regexp(szz, '(\d+)w', 'tokens');
    nhc = regexp(szz, '(\d+)d', 'tokens');

```

```

%进行数据的预处理和整理

if ~isempty(whr)

    plm = str2double(whr{1}{1});

else

    plm = 0;

end

if ~isempty(nhc)

    szx = str2double(nhc{1}{1});

else

    % 尝试提取 + 后面的天数

    plus_part = regexp(szz, '\+(\d+)', 'tokens');

    if ~isempty(plus_part)

        szx = str2double(plus_part{1}{1});

    else

        szx = 0;

    end

end

yqh(i) = plm + szx/7;

end

% 筛选男胎数据,要求 Y 染色体浓度要大于 0

fj = ~isnan(yrstnd) & yrstnd >= 0;

```



```

qmzjaj = table(yfdm(fj), nl(fj), sg(fj), kg(fj), ...
              yqh(fj), imb(fj), yrstnd(fj), ...
              yscxzds(fj), ckjybdbl(fj), gc(fj), ...
              'VariableNames', {'PregnantCode', 'Age', 'Height', 'Weight',
                                'GestationalWeek', ...
                                'BMI', 'YConc', 'TotalReads', 'MappingRatio', 'GCCContent'});%创建
    男胎数据对应的表格，方便后续建模

% 若某个数值存在缺失，则需要去除这个样本
eiowk = ismissing(qmzjaj, {'GestationalWeek', 'BMI', 'Age', 'Height', 'Weight',
                            'YConc'});
qmzjaj(any(eiowk, 2), :) = [];

% 考虑 bmi 不应太夸张，应在 18--25 之间
qgzj = (qmzjaj.GestationalWeek >= 10) & (qmzjaj.GestationalWeek <= 25);
pqknjds = (qmzjaj.BMI >= 18) & (qmzjaj.BMI <= 50);
jkquhw = qgzj & pqknjds;
qmzjaj = qmzjaj(jkquhw, :);

% 这里需要计算得出每个孕妇她所对应差值
[lck, ~, ic] = unique(qmzjaj.PregnantCode);
xym = zeros(size(lck));
for i = 1:length(lck)
    iiddxx = (ic == i);
    if sum(iiddxx) > 1%判断此组是否有多个数据点
        xym(i) = std(qmzjaj.YConc(iiddxx));
    else

```

```

        xym(i) = NaN; % 只检测一次，之后的缺失值用组均值来补充
    end
end

% 修复：正确添加新列到表格
ylp = size(qmzjaj, 1); % 获取表格行数
ycuowu = NaN(ylp, 1);
for i = 1:length(lck)
    iiddxx = (ic == i);
    ycuowu(iiddxx) = xym(i);
end

% 确保此前创建的仍然是表格，然后添加上新的列表
if istable(qmzjaj)
    qmzjaj.ErrorY = ycuowu; % 添加上新的列
else
    % 假如结果错误，重新创建一个表格
    qmzjaj = array2table([table2array(qmzjaj), ycuowu], ...
        'VariableNames', [qmzjaj.Properties.VariableNames, {'ErrorY'}]);
end

%将数据集中的缺失值补齐
[g, lyq] = findgroups(floor(qmzjaj.BMI));%创建 bmi 分组，并生成索引
rjf = splitapply(@nanmean, qmzjaj.ErrorY, g);%计算非缺失值中的平均值
for i = 1:length(lyq)
    iiddxx = (g == i) & isnan(qmzjaj.ErrorY);

```

```

    qmzjaj.ErrorY(iiddxx) = rjf(i);
end

T = zeros(length(lck), 1);%这是达标变量
for i = 1:length(lck)
    iiddxx = (ic == i);
    lzp = qmzjaj.YConc(iiddxx);
    plm = qmzjaj.GestationalWeek(iiddxx);
    above4 = find(lzp >= 0.04, 1);%找出达标值
    if ~isempty(above4)
        T(i) = plm(above4);
    else
        T(i) = plm(end); % 如果没有达标则取最后一周
    end
end
end

%去掉重复值，只留一人一组数据
[~, first_occurrence] = unique(ic);
xht = qmzjaj(first_occurrence, :);
xht.T = T;

% 定义自变量
xxx = [xht.BMI, xht.Age, xht.Height, xht.Weight, ...
    xht.TotalReads, xht.MappingRatio, xht.GCCContent, xht.ErrorY];

% 标准化自变量

```

```

hjh = zscore(xxx);

%% 2. 进行逐步回归分析
% 因变量：达标变量
% 自变量：标准化后的 hjh

mdl = stepwiselm(hjh, xht.T, 'Upper', 'linear', 'Criterion', 'aic');

% 将结果展示出来
disp('逐步回归结果:');
disp(mdl);

% 得到可视化的回归系数
figure;
bar(mdl.Coefficients.Estimate(2:end));
set(gca, 'XTickLabel', mdl.CoefficientNames(2:end));
xtickangle(45);
title('逐步回归系数');
ylabel('系数值');
grid on;

%% 3. 进行类分析
% 找到最显著的变量进行分类
% 这里假设主要因素是显著变量
ljsx = [xht.BMI, xht.Age, xht.TotalReads, xht.ErrorY];
tzc = zscore(ljsx);

```

```
% 确定 K 值，因为在此处分组效率最高，运用了肘部法则
```

```
mdh = 8;
```

```
wss = zeros(mdh, 1);
```

```
for ysx = 1:mdh
```

```
    [iiddxx, ~, sumd] = kmeans(tzx, ysx, 'Replicates', 10);
```

```
    wss(ysx) = sum(sumd);
```

```
end
```

```
figure;
```

```
plot(1:mdh, wss, 'bo-');%画出聚类图
```

```
xlabel('聚类数量 K');
```

```
ylabel('组内平方和 (WSS)');
```

```
title('肘部法则确定最佳 K 值');
```

```
grid on;
```

```
% 选择 K（这里假设 K=4——肘部法则）
```

```
ysx = 4;
```

```
[idx_clust, centroids] = kmeans(tzx, ysx, 'Replicates', 10);
```

```
% 计算轮廓系数
```

```
silh = silhouette(tzx, idx_clust);
```

```
figure;
```

```
silhouette(tzx, idx_clust);
```

```
title('轮廓系数');
```

```

% 根据前两个主视化成分，绘制图像

[coeff, score] = pca(tzx);
figure;
gscatter(score(:,1), score(:,2), idx_clust);
title('聚类结果（PCA 降维）');%确定标题
xlabel('第一主成分');
ylabel('第二主成分');

wwl = table();%提取每组原始数据
for i = 1:ysx
    qxh = xht.BMI(idx_clust == i);
    dxl = xht.Age(idx_clust == i);
    hby = xht.T(idx_clust == i);
    llt = xht.ErrorY(idx_clust == i);

    %计算各统计量
    wwl.Group(i) = i;
    wwl.BMI_min(i) = min(qxh);%计算当前组的最小值
    wwl.BMI_max(i) = max(qxh);%计算当前组的最大值
    wwl.AvgAge(i) = mean(dxl);%计算当前组的平均值
    wwl.AvgT(i) = mean(hby);
    wwl.AvgError(i) = mean(llt);
end

disp('分组统计:');
disp(wwl);

```

```

%% 4.确定每组的最佳时点
% 计算每个组的风险达标值
alal = 0.6; % 风险权重
ranget = 10:0.5:25; % 孕周范围

% 初始化
tbest = zeros(ysx, 1);
minF = zeros(ysx, 1);

figure;
for i = 1:ysx
    whj = (idx_clust == i);
    xch = xht.PregnantCode(whj);

    % 获取该组所有孕妇的所有检测数据
    wsm = ismember(qmzjaj.PregnantCode, xch);
    hlh = qmzjaj.GestationalWeek(wsm);
    sjy = qmzjaj.YConc(wsm);

    % 计算得出在每个时间段达标的比例
    pyq = zeros(size(ranget));%创立一个 0 向量
    for j = 1:length(ranget)
        wyq = ranget(j);
        near_idx = abs(hlh - wyq) < 0.5; % 选择差距在 0.5 周之内的样本数据
        if sum(near_idx) > 0

```

```

        pyq(j) = mean(sjy(near_idx) >= 0.04);
    else
        pyq(j) = 0;
    end
end

% 定义风险函数，为各个风险程度赋值
lyx = zeros(size(ranget));
lyx(ranget <= 12) = 1;
lyx(ranget > 12 & ranget <= 27) = 3;
lyx(ranget > 27) = 5;

% 计算 F(t)
tF = alal * lyx + (1 - alal) * (1 - pyq);

% 找到最小 F(t)对应的 t
[minF(i), idx_min] = min(tF);
tbest(i) = ranget(idx_min);

subplot(2,2,i);%绘制 ft 曲线
plot(ranget, tF, 'b-', tbest(i), minF(i), 'ro');
title(sprintf('Group %d: Best t=%.1f weeks', i, tbest(i)));
xlabel('孕周 (周)');
ylabel('F(t)');
grid on;
end

```

```

% 输出最佳时点
disp('最佳 NIPT 时点:');
for i = 1:ysx
    fprintf('Group %d (BMI: %.1f-%.1f): %.1f weeks\n', ...
        i, wwl.BMI_min(i), wwl.BMI_max(i), tbest(i));
end

%% 5. 对检测误差可能产生的影响的分析
% 增加 0.2 和 0.5 的误差影响，看结果如何
up = [0.2, 0.5];
jg = zeros(ysx, length(up));

for e = 1:length(up)
    for i = 1:ysx
        whj = (idx_clust == i);
        xch = xht.PregnantCode(whj);

        % 得到此组孕妇所有数据
        wsm = ismember(qmzjaj.PregnantCode, xch);
        hlh = qmzjaj.GestationalWeek(wsm);
        sjy = qmzjaj.YConc(wsm);
        llt = qmzjaj.ErrorY(wsm);

        % 模拟误差增加
        mnup = llt * (1 + up(e));
    end
end

```

```

mny = sjy + randn(size(sjy)) .* mnup;

% 用于风险分析中

wyq = tbest(i);
near_idx = abs(hlh - wyq) < 0.5;
if sum(near_idx) > 0
    R_t_sim = mean(mny(near_idx) >= 0.04);
else
    R_t_sim = 0;
end

risk_val = 1*(wyq<=12) + 3*(wyq>12&wyq<=27) + 5*(wyq>27);%风险随着时间增加而增加

F_t_sim = alal * risk_val + (1 - alal) * (1 - R_t_sim);

jg(i, e) = (F_t_sim - minF(i)) / minF(i) * 100;
end
end

% 显示误差影响
disp('误差增加对 F(t)的影响(%):');
disp(jg);

% 将误差影响可视化
figure;
bar(jg);
set(gca, 'XTickLabel', 1:ysx);

```

```

xlabel('组别');

ylabel('F(t)增加百分比 (%)');

legend('20%误差', '50%误差');

title('检测误差对最佳时点的影响');

grid on;

```

附录 4

介绍：基于随机森林构建判断女胎是否异常模型

```

%% 问题 4 开始，清除先前代码

clear; clc; close all;

%% 1. 读取附件数据

% 注意：这里需要将文件名改为您实际的文件名

data = readtable('女胎检测数据.xlsx');

%% 2. 采取索引方式明确各列信息

% 依据表的结构，确定各列的索引位置

% 13 号染色体 Z 值,18 号染色体 Z 值,21 号染色体 Z 值,X 染色体 Z 值,GC 含量

rst13z = data{:, 17};

rst18z = data{:, 18};

rst21z = data{:, 19};

rstx = data{:, 20};

gc = data{:, 16};

imbimb = data{:, 11}; % BMI

wybddd = data{:, 15}; % 唯一比对的读段数

yqh = data{:, 13}; % 在参考基因组上比对的比例

```

```

szz = data{:, 14}; % 重复读段的比例

whr = data{:, 12}; % 原始读段数


X = [rst13z, rst18z, rst21z, rstx, gc, imbimb, wybdddds, yqh, szz, whr]; % 创立特征矩阵，用于后续处理


%% 产生一个特征标签 Y
% 染色体 Z 值 >= 3，需要将其认定为异常
yccy = zeros(size(rst13z));
yccy(abs(rst13z) > 3 | abs(rst18z) > 3 | abs(rst21z) > 3 | abs(rstx) > 3) = 1;


%% 4. 添加 GC 含量约束条件 (40%-60%)
% 创建 GC 含量有效性标志
qpwo = (gc >= 0.4 & gc <= 0.6);

fprintf('总样本数: %d\n', length(yccy));

fprintf('GC 含量在 40%%-60%%范围内的样本数: %d (%.2f%%)\n', sum(qpwo),
sum(qpwo)/length(yccy)*100);


%% 5. 去掉不符合要求的数值
abcdefg = ~any(isnan(X), 2) & ~isnan(yccy) & qpwo;
X = X(abcdefg, :);
yccy = yccy(abcdefg);


z21_valid = rst21z(abcdefg); % 后续可视化需要
gvv = gc(abcdefg); % 保存有效的 GC 含量值

```

```
fprintf('符合 GC 含量约束且无缺失值的样本数: %d\n', length(yccy));
fprintf('异常样本数: %d (%.2f%%)\n', sum(yccy), sum(yccy)/length(yccy)*100);
fprintf(' 正 常 样 本 数 :   %d   (%.2f%%)\n',   sum(yccy==0),
sum(yccy==0)/length(yccy)*100);
```

%% 6. 得到训练和测试所需的集合

```
rng(42);
cv = cvpartition(yccy, 'HoldOut', 0.3);
xunlian = training(cv);
ceshi = test(cv);

xtrin = X(xunlian, :);
ytrin = yccy(xunlian);
xtest = X(ceshi, :);
ytest = yccy(ceshi);
```

%% 7. 通过训练和测试，优化随机森林模型

```
trees = 100;
feayures = round(sqrt(size(xtrin, 2)));

rfModel = TreeBagger(trees, xtrin, ytrin, ...
    'Method', 'classification', ...
    'OOBPrediction', 'on', ...
    'OOBVarImp', 'on', ...
    'NumPredictorsToSample', feayures);
```

%% 8. 预测结果，并评估其有效性

```
[nhc, scores] = predict(rfModel, xtest);

nhc = str2double(nhc);

accuracy = sum(nhc == ytest) / length(ytest);
fprintf('准确率: %.2f%%\n', accuracy * 100);

% 计算其他评估指标

zy = sum((nhc == 1) & (ytest == 1));
jx = sum((nhc == 1) & (ytest == 0));
tn = sum((nhc == 0) & (ytest == 0));
nf = sum((nhc == 0) & (ytest == 1));

%计算精确率
if (zy + jx) > 0
    precision = zy / (zy + jx);
else
    precision = 0;
end

%计算召回率
if (zy + nf) > 0
    recall = zy / (zy + nf);
else
    recall = 0;
end
```

```

%计算 F1 分数
if (precision + recall) > 0
    dfff = 2 * (precision * recall) / (precision + recall);
else
    dfff = 0;
end

fprintf('精确率: %.2f%%\n', precision * 100);
fprintf('召回率: %.2f%%\n', recall * 100);
fprintf('F1 分数: %.2f%%\n', dfff * 100);

cm = confusionmat(ytest, nhc);

%% 9. 生成所需 4 个子图，完成建模可视化
figure('Position', [100, 100, 1200, 900]);

subplot(2, 3, 1); % 生成四个子图，需要分成四块区域
importance = rfModel.OOBPermutedVarDeltaError; % 给各个指标进行排名
barh(importance);
set(gca, 'YTick', 1:size(X, 2));
set(gca, 'YTickLabel', {'Z13', 'Z18', 'Z21', 'ZX', 'GC', 'BMI', 'UniqueReads',
'MappedRatio', 'DupRatio', 'RawReads'});
title('特征重要性');
xlabel('重要性得分');

subplot(2, 3, 2);
confusionchart(cm, {'正常', '异常'});

```

```
title(sprintf('混淆矩阵 (准确率: %.2f%%)', accuracy*100)); % 创建出混淆矩阵的代码，并添加上标题
```

```
if size(scores, 2) > 1 % 保证模型输出了概率分数
```

```
    [sorted_scores, idx] = sort(scores(:,2), 'descend'); % 判断其确信度
```

```
    solaber = ytest(idx);
```

```
    ttt = cumsum(solaber) / sum(solaber);
```

```
    fff = cumsum(~solaber) / sum(~solaber);
```

```
    auc = trapz(fff, ttt); % 计算 AUC 的面积
```

```
    subplot(2, 3, 3);
```

```
    plot(fff, ttt, 'LineWidth', 2);
```

```
    hold on;
```

```
    plot([0, 1], [0, 1], 'r--');%绘制出随机参考线
```

```
    xlabel('假阳性率 ');
```

```
    ylabel('真阳性率 ');
```

```
    title(sprintf('ROC 曲线 (AUC=%.3f)', auc));
```

```
    legend('随机森林', '随机猜测', 'Location', 'southeast');%添加图例
```

```
    grid on;
```

```
else
```

```
    subplot(2, 3, 3);
```

```
    text(0.5, 0.5, '无法计算 ROC 曲线', 'HorizontalAlignment', 'center');
```

```
    title('ROC 曲线');
```

```
end
```

```
subplot(2, 3, 4);
```

```
alskdj = z21_valid(yccy == 0); % 正常标签
```

```

qpalzm = z21_valid(yccy == 1); % 不正常标签

% 用于比较不同群体的分布特征
if ~isempty(alskdj) % 起到保护作用
    histogram(alskdj, 'BinWidth', 0.5, 'FaceColor', [0.2, 0.6, 0.8], 'FaceAlpha', 0.7,
'Normalization', 'probability');
    hold on; % 保持所有的图形元素
end

%在此检查好所得数据并绘制直方图
if ~isempty(qpalzm)
    histogram(qpalzm, 'BinWidth', 0.5, 'FaceColor', [0.8, 0.2, 0.2], 'FaceAlpha', 0.7,
'Normalization', 'probability');
end

xlabel('21 号染色体 Z 值');
ylabel('频率');
title('21 号染色体 Z 值分布');

if ~isempty(alskdj) && ~isempty(qpalzm) % 判断两个数据集是否都正常
    legend('正常样本', '异常样本');
elseif ~isempty(alskdj)
    legend('正常样本');
elseif ~isempty(qpalzm)
    legend('异常样本');
end

```

```

grid on;

% 分别添加了阈值线
xline(3, 'r--', 'LineWidth', 2, 'Label', '异常阈值 (Z=3)');
xline(-3, 'r--', 'LineWidth', 2);

subplot(2, 3, 5);
histogram(gvv, 'BinWidth', 0.01, 'FaceColor', [0.4, 0.8, 0.4], 'FaceAlpha', 0.7); % 得到
cg 含量的分布图
xlabel('GC 含量');
ylabel('频率');
title('GC 含量分布 (40%-60%范围内)');
grid on;

% 在图表里加上分割线
xline(0.4, 'r--', 'LineWidth', 2, 'Label', '下限 (40%)');
xline(0.6, 'r--', 'LineWidth', 2, 'Label', '上限 (60%)');

%% 10. 蒙特卡洛模拟准确性检验
fprintf('\n===== 开始蒙特卡洛模拟检验 =====\n');

% 设置蒙特卡洛模拟参数
nstimus = 500; % 模拟次数
aces = zeros(nstimus, 1);
pres = zeros(nstimus, 1);
ral = zeros(nstimus, 1);
fscs = zeros(nstimus, 1);

```

```

% 记录原始数据

xfull = X;
yfull = yccy;

% 进行蒙特卡洛模拟
for i = 1:nstimus

    % 随机划分训练集和测试集 (70%/30%)

    rng(i); % 设置不同的随机种子

    cv_mc = cvpartition(yfull, 'HoldOut', 0.3);

    tidx = training(cv_mc);

    teidx = test(cv_mc);

    xtmc = xfull(tidx, :);

    ytmc = yfull(tidx);

    xtemc = xfull(teidx, :);

    ytemc = yfull(teidx);

    % 训练随机森林模型

    rfModel_mc = TreeBagger(trees, xtmc, ytmc, ...

        'Method', 'classification', ...

        'NumPredictorsToSample', feayures);

    % 预测

    ypredmccc = predict(rfModel_mc, xtemc);

    ypredmccc = str2double(ypredmccc);

```

```

% 计算评估指标

aces(i) = sum(ypredmccc == ytemc) / length(ytemc);

% 计算精确率、召回率和 F1 分数，保证模型的鲁棒性

tp = sum((ypredmccc == 1) & (ytemc == 1));
fp = sum((ypredmccc == 1) & (ytemc == 0));
fn = sum((ypredmccc == 0) & (ytemc == 1));

if (tp + fp) > 0
    pres(i) = tp / (tp + fp);
else
    pres(i) = 0;
end

if (tp + fn) > 0
    ral(i) = tp / (tp + fn);
else
    ral(i) = 0;
end

if (pres(i) + ral(i)) > 0
    fscs(i) = 2 * (pres(i) * ral(i)) / (pres(i) + ral(i));
else
    fscs(i) = 0;
end

```

```

% 显示进度

if mod(i, 50) == 0
    fprintf('已完成 %d/%d 次模拟\n', i, nstimus);
end
end

% 绘制蒙特卡洛模拟结果
subplot(2, 3, 6);
histogram(aces, 20, 'Normalization', 'probability', 'FaceColor', [0.5, 0.5, 0.8],
'FaceAlpha', 0.7);
hold on;
line([mean(aces), mean(aces)], ylim, 'Color', 'r', 'LineWidth', 2, 'LineStyle', '--');
xlabel('准确率');
ylabel('概率密度');
title(sprintf('蒙特卡洛模拟准确率分布\n(均值=%.3f, 标准差=%.3f)', mean(aces),
std(aces)));
legend('准确率分布', '平均值', 'Location', 'northwest');
grid on;

% 保存图像
saveas(gcf, '女胎异常判定模型_随机森林.png');

%% 11. 输出模型总结和蒙特卡洛模拟结果
fprintf('\n===== 模型总结 =====\n');
fprintf('异常判定标准: 任何染色体 Z 值绝对值 > 3\n');
fprintf('GC 含量约束: 40%%-60%%\n');

```

```

fprintf('总样本数: %d\n', length(yccy));

fprintf('异常样本数: %d (%.2f%%)\n', sum(yccy), sum(yccy)/length(yccy)*100);

fprintf(' 正 常 样 本 数 :   %d   (%.2f%%)\n',   sum(yccy==0),
sum(yccy==0)/length(yccy)*100);

fprintf('模型准确率: %.2f%%\n', accuracy*100);


if exist('auc', 'var')
    fprintf('模型 AUC: %.3f\n', auc);
end

fprintf('F1 分数: %.2f%%\n', dff*100);


% 输出最重要的 5 个特征
[~, idx] = sort(importance, 'descend');
fprintf('\n 最重要的 5 个特征:\n');

feature_names = {'Z13', 'Z18', 'Z21', 'ZX', 'GC', 'BMI', '唯一比对序列', '比对比例', '重
复比例', '原始读段数'};

for i = 1:min(5, length(importance))
    fprintf('%d. %s (重要性: %.4f)\n', i, feature_names{idx(i)}, importance(idx(i)));
end


% 输出 GC 含量统计信息
fprintf('\nGC 含量统计信息:\n');

fprintf('最小值: %.4f\n', min(gvv));

fprintf('最大值: %.4f\n', max(gvv));

fprintf('平均值: %.4f\n', mean(gvv));

fprintf('中位数: %.4f\n', median(gvv));

```

```

% 输出蒙特卡洛模拟结果

fprintf('\n===== 蒙特卡洛模拟结果 (%d 次) =====\n', nstimus);
fprintf('准确率 - 均值: %.3f, 标准差: %.3f, 范围: [%.3f, %.3f]\n', ...
        mean(aces), std(aces), min(aces), max(aces));
fprintf('精确率 - 均值: %.3f, 标准差: %.3f\n', mean(pres), std(pres));
fprintf('召回率 - 均值: %.3f, 标准差: %.3f\n', mean(ral), std(ral));
fprintf('F1 分数 - 均值: %.3f, 标准差: %.3f\n', mean(fscs), std(fscs));

%画出蒙特卡洛随机模拟图像

figure('Position', [100, 100, 1200, 800]);

subplot(2, 2, 1);
histogram(aces, 20, 'Normalization', 'probability', 'FaceColor', [0.2, 0.6, 0.8]);
xlabel('准确率');
ylabel('概率密度');
title('准确率分布');
grid on;

subplot(2, 2, 2);
histogram(pres, 20, 'Normalization', 'probability', 'FaceColor', [0.8, 0.2, 0.2]);
xlabel('精确率');
ylabel('概率密度');
title('精确率分布');
grid on;

```

```
subplot(2, 2, 3);  
  
histogram(ral, 20, 'Normalization', 'probability', 'FaceColor', [0.8, 0.6, 0.2]);  
  
xlabel('召回率');  
  
ylabel('概率密度');  
  
title('召回率分布');  
  
grid on;  
  
  
subplot(2, 2, 4);  
  
histogram(fscs, 20, 'Normalization', 'probability', 'FaceColor', [0.4, 0.8, 0.4]);  
  
xlabel('F1 分数');  
  
ylabel('概率密度');  
  
title('F1 分数分布');  
  
grid on;  
  
  
sgtitle(sprintf('蒙特卡洛模拟评估指标分布 (%d 次模拟)', nstimus));  
  
  
% 保存蒙特卡洛模拟结果图  
  
saveas(gcf, '蒙特卡洛模拟结果.png');  
  
  
fprintf('\n 蒙特卡洛模拟完成，结果已保存。 \n');
```